

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

Modulo 8 — Costi, piano Pro e ottimizzazione

Metà dei token, a parità di qualità

Metà dei token, a parità di qualità

Un prompt troppo lungo, tre casi, e una misura prima e dopo

- **Obiettivo**, in 22 minuti: il prompt dell'assistenza di CiaspoLink, l'operatore inventato del corso, misurato su tre casi, si taglia con Claude Code e si rimisura. Meno token, e controlli e giudice non peggiori
- **Da dove si parte**, dalla guida ai costi: «Most agent requests carry tokens that never influence the answer.» e «Trimming them rarely costs output quality, although not every lever here saved money when measured.»
- **Che cosa c'è già:** il prompt `v0`, con la guida al tono e le procedure dentro; tre messaggi di clienti; controlli scritti in codice e un giudice su Haiku
- **La metà** è l'obiettivo del laboratorio: un numero che la verifica stampa e non giudica. Il prompt è costruito per il corso: una coppia di misure è una dimostrazione, e non decide quelle frasi
- Il README: `m8_costi_ottimizzazione/s6_costi_e_ottimizzazione/m8_e2_meta_dei_token/M8-E02_meta_dei_token/`

Misurare v0

Prima il prompt com'è: quanto pesa, e che cosa risponde

- Dalla cartella `esercitazioni`; alla domanda se vi fidate della cartella rispondete sì:

```
tools/prepara_esercizio.sh M8-E02
cd ~/corso-claude-code/M8-E02
claude --model sonnet
```

- Nella sessione, con il punto esclamativo davanti, il comando va alla shell senza passare da Claude:

```
! ./misura.sh v0
```

- Per ogni caso: la risposta su Sonnet, con effort low e senza strumenti, i controlli, il giudizio. Le colonne: token in entrata (i tre campi sommati), token in uscita, costo ricalcolato, controlli, giudice
- Leggete almeno una risposta, in `risposte/v0/`: è quella che poi cercate di non peggiorare

Tagliare, con Claude Code

Il prompt del passo 3 del README, nel template del corso

il prompt del passo 3, a capo per la slide, 1 di 3

```
<role>
Sei un collega esperto di prompt e lavori per il team
dell'assistenza di CiaspoLink: riduci i token di un prompt senza
perdere qualità nelle risposte.
</role>

<context>
prompt/v0.md è il prompt con cui l'assistente virtuale risponde ai
clienti: è lungo e ripetitivo. I segnaposto {{tono}} e
{{procedure}} includono documenti/tono.md e
documenti/procedure.md; {{messaggio}} e {{stato}} portano i dati
di ciascuno dei tre casi di casi/. Ogni versione si misura con
misura.sh, con i controlli scritti in codice di
casi/*/controlli.tsv e un giudice che legge le affermazioni di
casi/*/rubrica.md. Il risultato lo usa chi lancia misura.sh per
confrontare i token e la qualità delle risposte.
</context>
```

Tagliare, con Claude Code

Il prompt del passo 3 del README, nel template del corso

il prompt del passo 3, a capo per la slide, 2 di 3

```
<instructions>
1. Leggi prompt/v0.md, documenti/tono.md e documenti/procedure.md,
   e in casi/ i messaggi, gli stati, i controlli e le rubriche.
2. Scrivi prompt/v1.md partendo da prompt/v0.md: togli ciò che non
   cambia la risposta, cioè le ripetizioni e la presentazione
   dell'azienda.
3. Riassumi la guida al tono e le procedure nelle sole regole che
   la risposta richiede: togli i segnaposto {{tono}} e
   {{procedure}} se i documenti non ti servono più; {{messaggio}}
   e {{stato}} restano.
4. Tieni ciò che i controlli e le rubriche chiedono e il formato
   della risposta, nel canale che lo stato indica.
5. Per ultimo rileggi prompt/v1.md e controlla che ogni regola
   chiesta dalle rubriche e dai controlli ci sia ancora e che
   {{messaggio}} e {{stato}} ci siano; correggi ciò che manca.
</instructions>
```

Tagliare, con Claude Code

Il prompt del passo 3 del README, nel template del corso

il prompt del passo 3, a capo per la slide, 3 di 3

```
<format>
Scrivi soltanto prompt/v1.md. Nella risposta, al massimo otto
righe: che cosa hai tolto, che cosa hai riassunto, che cosa hai
tenuto e perché.
</format>

<constraints>
Cambia soltanto prompt/v1.md. Tieni tutti i fatti e le regole che
i controlli e le rubriche chiedono, in italiano, e scegli le
parole che servono al risultato.
</constraints>
```

Si copia dal README, non dalla slide. Se Claude Code chiede il permesso di scrivere `prompt/v1.md`, leggete e approvate

Rimisurare e confrontare

La stessa misura sulla versione nuova, poi la coppia

```
! ./misura.sh v1
! ./misura.sh --confronta v0 v1
```

- Il confronto mette v0 e la vostra versione fianco a fianco, per caso e in totale: token in entrata e in uscita, controlli, giudice
- Due righe: la riduzione dei token in entrata, in percentuale, e l'obiettivo del laboratorio, almeno il 50 %: un dato, che non decide niente
- Se controlli o giudice sono scesi la verifica non passa: `cp prompt/v1.md prompt/v2.md`, la richiesta del README per correggere v2, e misurate v2

Lavoro e verifica

A timer, poi che cosa dice il controllo

- **Il lavoro, 12 minuti a timer:** misurate v0, tagliate con il prompt del README, rimisurate e confrontate. Se resta tempo, o se la verifica non passa, una v2
- Che cosa cercare: quello che si ripete; quello che si può riassumere in regole; quello che si può recuperare invece di incollare
- Alla fine: `/exit`, e dalla cartella `esercitazioni` `tools/verifica.sh M8-E02`
- Il costo ricalcolato dipende anche da che cosa è già in cache: il confronto che conta è sui token in entrata e sulla qualità

Lavoro e verifica

A timer, poi che cosa dice il controllo

	token in entrata	token in uscita	controlli	giudice
v0	30.768	833	23/23	13/15
v1 di riferimento	**6.459**	874	23/23	14/15

Dalla registrazione del corso, 10 novembre 2026, sui tre casi: una misura per versione. Riduzione dei token in entrata: 79,0 %

la verifica registrata, a capo per la slide

```
obiettivo del laboratorio: almeno il 50 % in meno
(una soglia del laboratorio, non una frase di Anthropic: non
decide l'uscita)
(dato) token in entrata scesi: sì; controlli e giudice non
peggiori: sì
```

- Passa se una versione dopo v0, con lo stesso modello e lo stesso effort, pesa meno e controlli e giudice non scendono. Una dimostrazione su un prompt costruito: una misura sola può variare
- A voce: quale taglio vi è costato qualità?
- Nella registrazione nessuno, in una misura sola. Se un criterio cambia esito da una misura all'altra, non è una prova: rimisurate

Quello che si può togliere si scopre misurando.