

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

Modulo 1 — Fondamenti degli LLM

Cosa fanno, cosa leggono, come imparano

Completate la frase

Buttatevi, senza paura

- Che cosa fa un LLM, che cosa legge, come impara: **si comincia da un gioco**
- Un gioco con settantacinque anni: nel 1951 Claude Shannon faceva indovinare un testo lettera per lettera — e le lettere indovinate erano **89 su 129**

«La riunione è stata rinviata a causa dello _____»

- A voce: **una parola**, la prima che vi viene — senza pensarci
- Dopo «dello» la lingua ammette **poche parole**: «gatto» o «lunedì» non ci stanno
- Avete prodotto il pezzo successivo **più probabile in base alla vostra esperienza** — e le vostre risposte tendono a convergere verso un insieme prestabilito: la lingua ha una statistica, e la conoscete senza saperlo

sciopero	molti, chissà perché...?
straordinario	qualcuno, stakanovista
slittamento dei lavori	chi lavora a progetto
spostamento della sede	qualcuno, freelance
stato di emergenza	pochi, nel periodo grandinate/supercelle
spegnimento dei server	un paio, sistemisti
sciame sismico	uno, il catastrofista

Alcune risposte raccolte

Raccolte dal docente fra colleghi e partecipanti di altri corsi — campione di comodo, non statistico

Avete appena fatto quello che fa un LLM

Prevedere il pezzo successivo, un pezzo alla volta

- Predice il pezzo successivo di un testo in base al **contesto**: tutto quello che ha davanti, non solo l'ultima parola
- Scrive **un pezzo alla volta**, in base a ciò che tende a seguire; lo attacca al testo e ricomincia — un autocompletamento molto sofisticato, **non un motore di ricerca**
- **Molti** compiti si possono scrivere come un testo da continuare: per esempio una domanda, seguita da «la risposta è» — qui sotto, un esempio costruito, non la risposta di un modello

> *(pensa) — Ho la domanda «Chi ha scritto L'origine della specie?» e voglio ottenere la risposta —*
> *«D: Chi ha scritto L'origine della specie? R: »*
> *(pensa) — Eseguo l'inferenza…—*
> *(pensa) — Prossimo token: «Charles» al 25%, «Darwin» al 15%, «cane» allo 0,2%, «gatto» allo 0,1%,…—*
> *«D: Chi ha scritto L'origine della specie? R: Charles»*
> *(pensa) — Prossimo token: «Darwin» al 65%, «Charles» all'1%,…—*
> *«D: Chi ha scritto L'origine della specie? R: Charles Darwin»*

Processo di *question answering*

- Però, dice Anthropic, un modello scrive una parola alla volta ma **non pensa** una parola alla volta. Dentro succede di più: per esempio l'attention, con cui ogni pezzo del testo pesa gli altri

Un LLM non «capisce e risponde»: continua il testo nel modo più probabile.
Tutto il resto discende da qui.

Probabilità che non si vedono

Perché nella prova che segue si contano le parole, invece di mostrare le probabilità

- A ogni passo il modello dà un punteggio — una **probabilità** — a ogni pezzo possibile; poi ne viene scelto uno, attaccato al testo, e si ricomincia
- Su Claude quei numeri **non si vedono**: il menu del modello di claude.ai regola tre cose — quale modello, quanto impegno (*effort*), se ragiona prima di rispondere (*thinking*) — e nessuna mostra le probabilità
- Nell'API la **temperatura**, la manopola del campionamento, sui modelli più recenti non si imposta: un valore diverso da quello predefinito dà un **errore**, e dalla versione dell'API del 21 ottobre 2026 qualunque valore — qui sotto, a 0 e a 1, registrata su un **modello aperto in locale**, non su Claude



Stesso prompt: a temperatura 0 lo stesso slogan in 5 esecuzioni su 5, 2 senza seed; a 1, con due seed, due slogan diversi
Registrazione del corso, 19 ottobre 2026: gemma3:4b in locale con Ollama, non Claude
© Simone Scannapieco

- Anche a temperatura zero, dove si può impostare, l'uscita **non è del tutto deterministica**
- Per questo, nella prova che segue, si **misura**: venti chiamate per modello, e le parole contate

Che cosa risponde Claude

La stessa frase, data a tre modelli Claude — più volte

- La stessa frase, venti volte a ciascun modello Claude — quante parole diverse?
- Demo **M1-D01**, dal vivo: tre chiamate per modello — Haiku, Sonnet, Opus. Guardate la parola di ogni chiamata, e quante parole diverse escono per modello

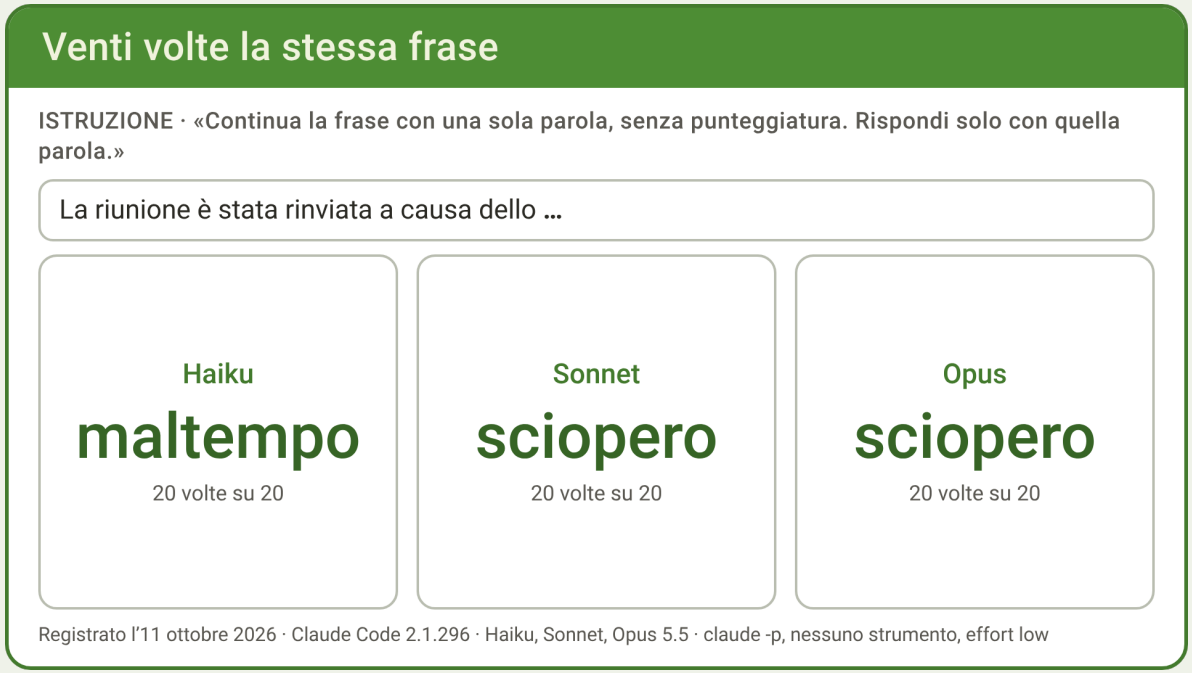
```
claude -p "$(cat frase.txt)" --model haiku \
  --effort low --tools "" \
  --system-prompt "$(cat istruzione.txt)" \
  --strict-mcp-config --no-session-persistence
```

- Una chiamata: `claude -p` è Claude Code non interattivo, stampa la risposta ed esce; le altre opzioni chiedono poco ragionamento e tolgono a Claude strumenti e server MCP (gli strumenti esterni, nel Modulo 4). La frase e l'istruzione stanno in due file. `frase.txt`: «La riunione è stata rinviata a causa dello» — `istruzione.txt`: «Continua la frase con una sola parola, senza punteggiatura. Rispondi solo con quella parola.»
- La registrazione del corso, nella pagina che segue, usa questo comando con quattro opzioni in più: `--setting-sources project,local`, nessuna impostazione dell'utente; `--permission-mode dontAsk` e `--permission-prompts none`, ciò che chiederebbe un permesso è negato; `--output-format json`, la risposta in JSON

Che cosa risponde Claude

La stessa frase, data a tre modelli Claude — più volte

La stessa frase, venti volte a ciascun modello Claude — quante parole diverse?



La registrazione del corso: la stessa frase e la stessa istruzione, venti chiamate per modello
© Simone Scannapieco — figura dalla registrazione dell'11 ottobre 2026

Anthropic, glossario: «input identici potrebbero produrre output diversi tra diverse chiamate API» — qui la temperatura è quella predefinita: questi modelli rifiutano ogni altro valore. Guida al prompting: «Claude risponde bene a istruzioni chiare ed esplicite»

Nella registrazione, venti chiamate per modello: Haiku «maltempo», Sonnet e Opus «sciopero», 20 su 20. Il controllo: output diversi **non dimostrati** — «potrebbero», non «devono», e dal vivo può uscire una parola diversa; l'istruzione, una parola sola, **rispettata** 20 su 20

Che cosa legge

Testo su scala web, e non solo

Fonte	Proporzione	Su disco	Token
CommonCrawl	67%	3,3 TB	circa 1.400 miliardi
C4	15%	783 GB	
GitHub	4,5%	328 GB	
Wikipedia	4,5%	83 GB	
Books (Gutenberg, Books3)	4,5%	85 GB	
ArXiv	2,5%	92 GB	
StackExchange	2%	78 GB	

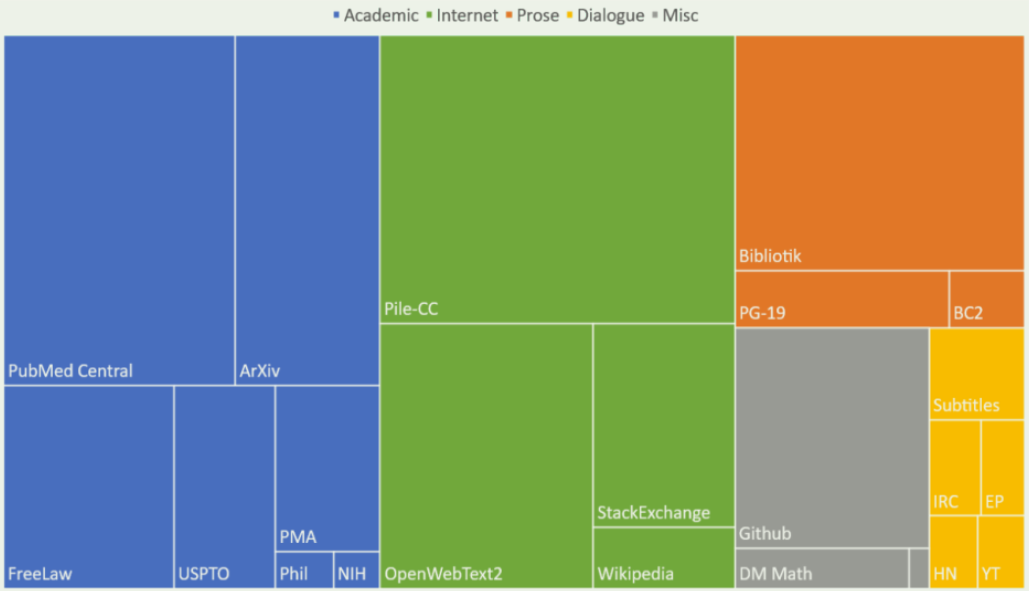
Il corpus di addestramento di LLaMA (Meta AI, febbraio 2023); i token sono i pezzi di testo che il modello vede, e li guardiamo da vicino nella parte «Token e finestra di contesto»

Touvron et al., arXiv 2302.13971, tabella 1

- Il grosso è testo dal **web**; poi codice, Wikipedia, libri, articoli scientifici, domande e risposte

Che cosa legge

Testo su scala web, e non solo



The Pile: 22 sottoinsiemi, 825 GiB di testo inglese, per dimensione effettiva
Gao et al., The Pile (arXiv 2101.00027), figura 1, CC BY 4.0; ritaglio

- Il grosso è testo dal **web**; poi codice, Wikipedia, libri, articoli scientifici, domande e risposte
- Testi scritti da persone: con la grammatica e i fatti ci sono anche **errori e pregiudizi** — e il modello impara anche quelli

Dal pre-training all’allineamento

Perché è gentile, segue le istruzioni e certe cose non le fa

- ***Pre-training***: apprendimento auto-supervisionato
  prevedere il pezzo successivo su enormi quantità di testo: grammatica, fatti, stili — ma non sa ancora «rispondere»
- ***Instruction tuning***: *fine-tuning* per seguire le istruzioni
  dimostrazioni del comportamento desiderato, scritte da persone
- **RLHF**, *Reinforcement Learning from Human Feedback*
  un modello di ricompensa impara le preferenze delle persone; il rinforzo spinge verso le risposte preferite (Ouyang et al., 2022)
- ***Constitutional AI*** (Anthropic, 2022): l’unica supervisione umana è un elenco di **principi**
  il modello critica e rivede da sé le risposte, poi il rinforzo usa giudizi dati da un’AI; oggi la costituzione di Claude ha un ruolo cruciale nel suo addestramento

Il comportamento «da assistente» è **aggiunto dopo**, non innato — e lascia impronte:
piaggeria, prolissità, eccesso di cautela, sicurezza mal calibrata

Nessun database

Dove sono le risposte?

- Nessuna tabella «domanda → risposta»: i fatti che sa recitare sono emersi **come effetto collaterale** del prevedere il testo
- Nel 2024, dentro un modello Claude in produzione, Anthropic ha individuato **milioni di concetti**, ciascuno distribuito su molte unità della rete, i suoi «neuroni» — e sono solo una piccola parte di quelli appresi
- Anthropic scrive di **non capire** come i modelli facciano la maggior parte delle cose che fanno: i loro «pensieri» non si leggono facilmente
- Non impara dalle vostre correzioni: risponde a ciò che ha **nel contesto**. La memoria di claude.ai scrive **note** e le rimette all'inizio della conversazione successiva

Nessuno ha programmato le risposte: sono emerse dai dati di addestramento.

Quiz lampo

Tre affermazioni: vero o falso? Ditelo a voce

1. Un LLM cerca la risposta in un database.
   FALSO — continua il testo; i fatti sono emersi dall'addestramento, non c'è una tabella da consultare.
2. Un LLM impara dalle vostre correzioni e domani ne terrà conto.
   FALSO — risponde a ciò che ha nel contesto. Se domani «ricorda», è la memoria di claude.ai: **note rimesse nel contesto**.
3. Nessuno ha scritto a mano le risposte di Claude.
   VERO — i modelli sono addestrati, non programmati direttamente.

Sappiamo *che cosa* fa un LLM, *che cosa* legge e *come* impara.

Nella parte successiva: che cosa vede — token e finestra di contesto.