

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

Modulo 1 — Fondamenti degli LLM

Token e finestra di contesto

Quanti token?

Come un LLM vede il testo, e quanto ne tiene: si parte dai token

«La riunione è stata rinviata a causa dello sciopero dei trasporti.»
11 parole, 66 caratteri

«The meeting has been postponed because of the transport strike.»
10 parole, 63 caratteri

Un tokenizer taglia il testo in pezzi, i token. In quanti pezzi taglia la frase italiana? Più o meno delle sue 11 parole? E dei suoi 66 caratteri?

La risposta è nella pagina che segue, con un tokenizer pubblico; quanti token pesa la frase per Claude lo misuriamo dal vivo nel secondo «Stessa frase, due lingue» (M1-D02).

La frase, spezzata

Un tokenizer taglia il testo in token: venti pezzi, e non sempre sono parole

Tokenizer

Testo:

La riunione è stata rinviata a causa dello sciopero dei trasporti.

Token (tokenizer OpenAI, o200k): **20** di 20

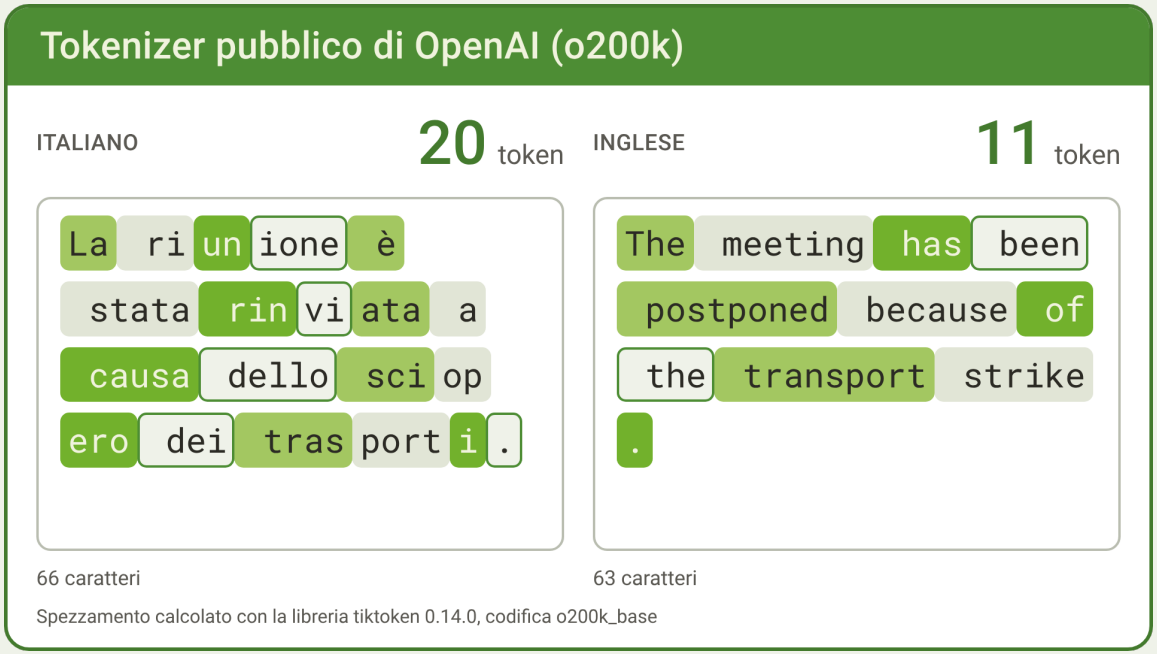


I venti pezzi della frase secondo il tokenizer pubblico di OpenAI (o200k)
Il tokenizer di Claude non è pubblico: un altro tokenizer, un altro numero
© Simone Scannapieco — spezzamento del tokenizer o200k, con la libreria tiktoken

- ✔ La risposta: **venti pezzi** — più delle 11 parole, molto meno dei 66 caratteri: un token **non** è una parola, e nemmeno una lettera
- Pezzi di parola: `ri` | un | `ione`, `sci` | op | `ero` — mentre «causa» e «dello» restano intere
- Il modello lavora su questi pezzi, **non sulle lettere** che ci sono dentro

Stessa frase, due lingue

Con il tokenizer pubblico di OpenAI (o200k): l’italiano costa più token dell’inglese



La stessa frase, in italiano e in inglese: 20 token contro 11
Spezzamenti del tokenizer pubblico di OpenAI (o200k), non di quello di Claude
© Simone Scannapieco — spezzamento del tokenizer o200k, con la libreria tiktoken

- Su questa frase, con questo tokenizer, l’italiano usa l’**82 % di token in più**
- In media, su duemila frasi tradotte da persone, un altro tokenizer di OpenAI, cl100k (ChatGPT e GPT-4), usa **circa 1,6 volte** i token dell’inglese per dire la stessa cosa in italiano (Petrov et al., NeurIPS 2023)
- E Claude? Il suo tokenizer non è pubblico: i suoi token li misuriamo **dal vivo**, con M1-D02, nella slide che segue

Stessa frase, due lingue

M1-D02, dal vivo: i token di Claude, letti nella risposta di Claude Code

- Quattro chiamate a Claude Code, su Haiku: la frase italiana, la stessa frase **due volte**, poi l'inglese, singola e doppia
- Guardate i **token in entrata** di ogni risposta: oltre alla frase il modello riceve sempre altro testo, come l'istruzione di sistema — la **differenza** fra frase doppia e frase singola è il peso della frase

```
claude -p "$(cat frase_it.txt)" --model haiku --effort low \
  --tools "" --system-prompt "$(cat istruzione.txt)" \
  --strict-mcp-config --no-session-persistence \
  --output-format json | python3 leggi_json.py token_entrata
```

- È la prima delle quattro chiamate, nello spazio di lavoro di `tools/prepara_esercizio.sh M1-D02`: i passi completi sono nel README dell'elemento, nel repository delle esercitazioni

Stessa frase, due lingue

M1-D02, dal vivo: i token di Claude, letti nella risposta di Claude Code

I token di Claude

ITALIANO

La riunione è stata rinviata a causa dello sciopero dei trasporti.

27 token

Haiku	27
Sonnet	27
Opus	27

INGLESE

The meeting has been postponed because of the transport strike.

17 token

Haiku	17
Sonnet	17
Opus	17

Stessa frase: **+59 %** in italiano. Conteggi uguali su Haiku, Sonnet e Opus.

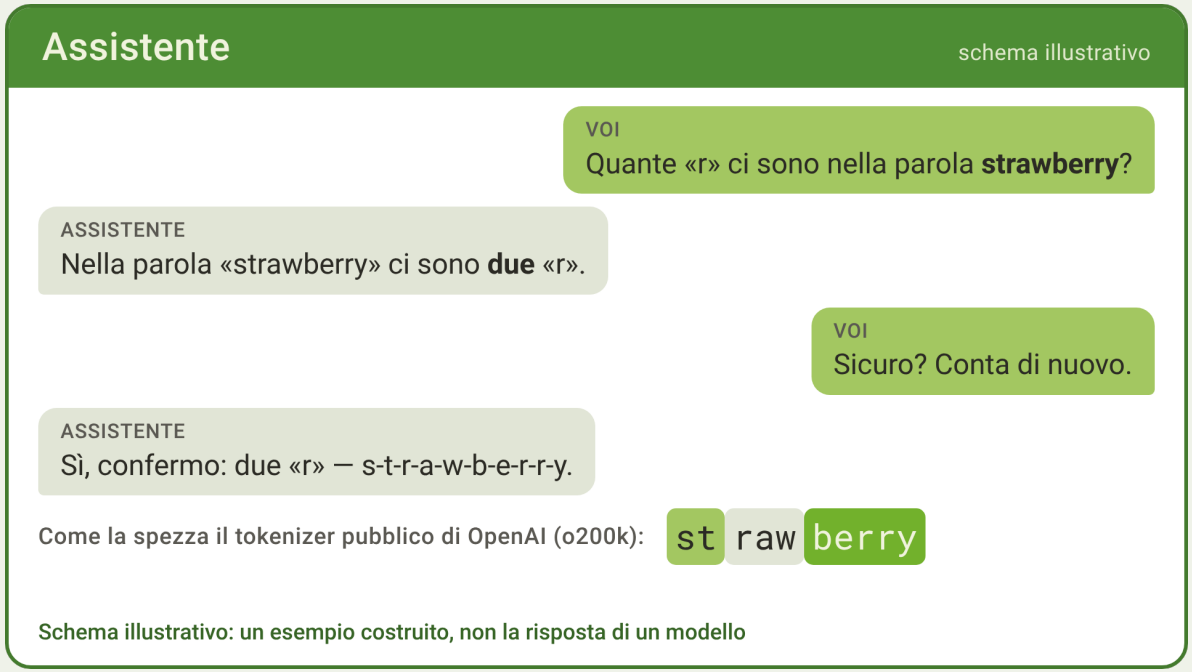
Registrato l'11 ottobre 2026 · Claude Code 2.1.296 · Haiku, Sonnet, Opus 5.5 · i token in entrata del JSON di claude -p, frase raddoppiata meno frase singola

La stessa frase in italiano e in inglese: i token in entrata di Claude, frase doppia meno frase singola
Registrazione del corso, 11 ottobre 2026: stessi conteggi su Haiku, Sonnet e Opus
© Simone Scannapieco — figura dalla registrazione

- Su questa frase l'italiano costa a Claude il **59 % di token in più**: un altro tokenizer, un altro numero, lo stesso verso
- Stesso contenuto, più token: **più consumo** del vostro limite d'uso e **meno spazio** nella finestra di contesto, tutto il testo che il modello consulta mentre risponde

Strawberry

Il caso famoso: quante «r» in «strawberry»?



Schema illustrativo: un esempio costruito, non la risposta di un modello
Lo spezzamento è misurato con il tokenizer pubblico di OpenAI (o200k)
© Simone Scannapieco

- ✔ Le «r» sono **tre**; la chat qui sopra è un esempio costruito. C'è stato un tempo in cui la maggior parte dei modelli sbagliava questo conteggio: un tutorial dell'Academy di Anthropic lo racconta **al passato**
- Con il tokenizer di OpenAI la parola è **tre pezzi**, `st` | `raw` | `berry`: nessuno è una lettera
- E Claude, oggi? Nella registrazione del corso risponde **3**, ogni volta, su tutti e tre i modelli: la trovate in «Contare le lettere»

Contare le lettere

M1-D03: prima provate voi in claude.ai, poi la registrazione sui tre modelli

In claude.ai, una **conversazione nuova**; il modello lo scegliete dal menu accanto al pulsante di invio: va bene quello che avete

```
claude.ai, conversazione nuova
```

```
Quante n ci sono nella parola interconnessione?
Rispondi solo con il numero.
```

Ditelo **a voce**: la risposta e il modello che avete usato; poi, nella stessa conversazione di claude.ai:

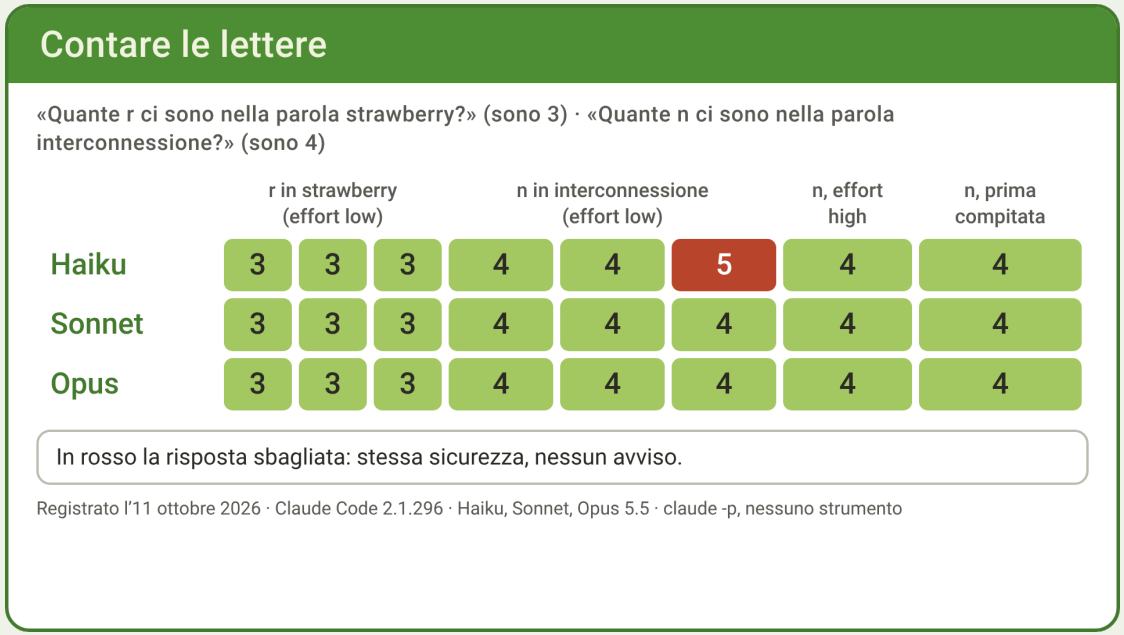
```
claude.ai, nella stessa conversazione
```

```
Scrivi la parola interconnessione una lettera per riga,
poi conta le n e dimmi quante sono.
```

In claude.ai contano anche la **memoria** e la **ricerca sul web**: risposte diverse fra voi fanno parte della prova

Contare le lettere

M1-D03: prima provate voi in claude.ai, poi la registrazione sui tre modelli



Quante r in «strawberry» (3) e quante n in «interconnessione» (4): ogni risposta registrata
Registrazione del corso, 11 ottobre 2026: in rosso l'unica risposta sbagliata
© Simone Scannapieco — figura dalla registrazione

- Strawberry: **3**, ogni volta. Interconnessione: Haiku, a effort basso, **4, 4 e 5**, con la stessa sicurezza; con più ragionamento, o con la parola compitata, **4**
- Perché: il modello lavora sui **pezzi**, non sulle lettere — gli studi lo legano alla tokenizzazione
- Per chi scrive codice: contare, misurare, validare un formato **non si delega** al modello; `grep -o n <<< interconnessione | wc -l` lo fa senza errori

Token, costi e limiti

Il metro di tutto il resto del corso

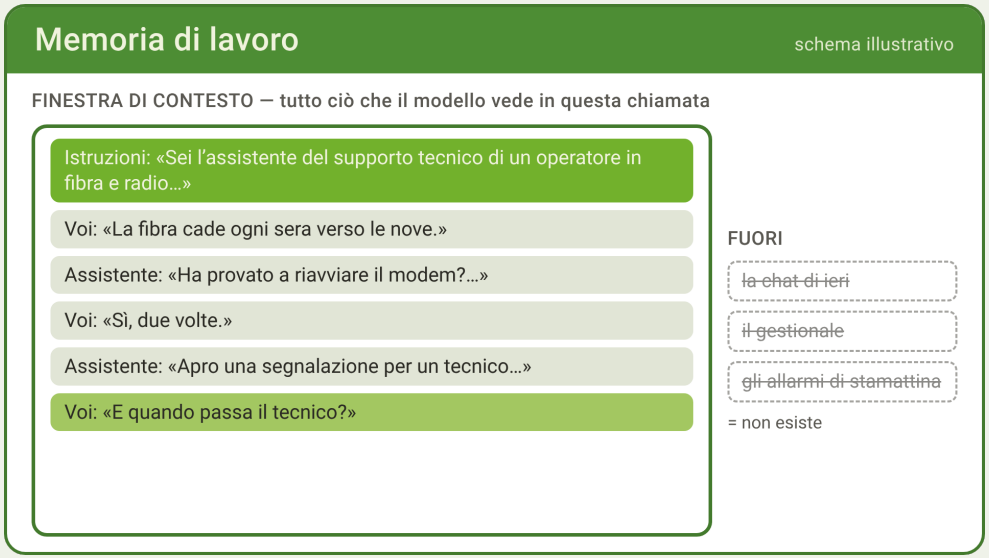
- Sull'API si paga **per milione di token**, in entrata e in uscita: l'uscita costa **5 volte** l'entrata, su tutti i modelli
- Fra modelli, in rapporti: rispetto a Haiku, Sonnet costa **20 volte** e Opus **40 volte** (il prezzo di Haiku vale per prompt fino a 100 mila token)
- Sul vostro abbonamento i token consumano il **limite d'uso**, e a ritmi diversi: Haiku il più leggero, Sonnet moderato, Opus pesante
- E il metro cambia con il modello: dai modelli Claude 4.7 in poi un tokenizer più recente dà circa il **30 % di token in più** per lo stesso testo

Il modello non vede lettere né parole: vede token — e i token sono il metro di costi e limiti.

I listini e il piano Pro, con i conti, nel Modulo 8.

La RAM del modello

La finestra di contesto: memoria di lavoro, non memoria permanente

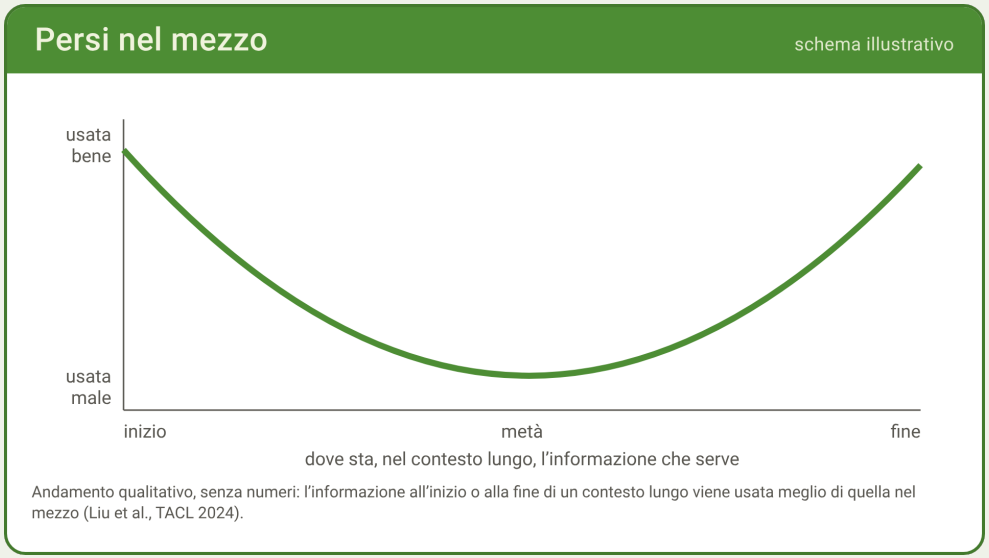


La finestra di contesto: tutto ciò che il modello vede in una chiamata, e ciò che ne resta fuori
Schema illustrativo: i testi sono inventati
© Simone Scannapieco

- È tutto il testo che il modello consulta mentre risponde, risposta compresa: la sua **memoria di lavoro**, distinta da ciò su cui è stato addestrato
- Ciò che è fuori, per il modello **non esiste**: per questo non impara dalle vostre correzioni, e la memoria di claude.ai, attiva di serie sul Pro, è **altro testo** rimesso nella finestra

Perché le chat lunghe perdono il filo

Vi è mai capitato? E che cosa avete fatto? Ditelo a voce



Dove sta, in un contesto lungo, l'informazione che serve, e quanto bene viene usata: una U

Schema illustrativo: l'andamento, non i dati dell'articolo

da Liu et al., «Lost in the Middle», TACL 2024

- Più token, meno precisione e meno richiamo: Anthropic chiama questo degrado **context rot**
- E conta **dove**: all'inizio e alla fine l'informazione si usa meglio che **nel mezzo**, anche nei modelli fatti per i contesti lunghi
- Rimedi: **in testa** ciò che conta; i testi lunghi **a pezzi**; le informazioni critiche **ripetute** — un log di migliaia di righe si filtra prima, non si incolla intero

Ogni chiamata riparte da zero

M1-D04, dal vivo: tre chiamate a Haiku in Claude Code

- **A**, in una sessione nuova: la linea LN-000204 e il suo guasto. **B**, in un'altra sessione nuova: «Quale linea seguo, e che guasto ha?». **C**: la stessa domanda nella sessione di A, **ripresa**
- Guardate che cosa rispondono B e C, e i **token in entrata** di A e di C

```
chiedi() {
  claude -p "$(cat "$1")" --model haiku --effort low --tools "" \
    --system-prompt "$(cat istruzione.txt)" --strict-mcp-config \
    --output-format json "${@:2}"
}
a="$(chiedi primo.txt)"
b="$(chiedi domanda.txt --no-session-persistence)"
c="$(chiedi domanda.txt --resume \
  "$(python3 leggi_json.py session_id <<< "$a")")"
```

Ogni chiamata riparte da zero

M1-D04, dal vivo: tre chiamate a Haiku in Claude Code



Tre chiamate a Haiku: due sessioni nuove, poi la prima ripresa (la risposta di B è tagliata: […])
Registrazione del corso, 11 ottobre 2026; linea e guasto inventati
© Simone Scannapieco — figura dalla registrazione

- B non sa niente; C sì, perché Claude Code ha **rimandato** al modello la conversazione di A: la Messages API è *stateless*, senza memoria fra una richiesta e l'altra, e a ogni richiesta si manda l'intera cronologia
- Per questo i token in entrata **crescono**, da 608 a 660: in una chat lunga, ogni turno rimanda tutta la finestra

Il modello non si ricorda di voi: ricorda solo ciò che gli rimandate ogni volta.

Ordini di grandezza

Fotografia di ottobre 2026: le finestre crescono, i nomi cambiano

Finestra	Chi, oggi
1 milione, nell’API	Claude Fable, Opus, Sonnet e Haiku di oggi; in uscita fino a 128 mila token
1 milione, sul Pro	Opus, Sonnet e Haiku 5.5, in claude.ai e in Claude Code
500 mila, in claude.ai	alcuni modelli precedenti, per esempio Opus 4.8 e Sonnet 4.6
200 mila, in claude.ai	gli altri modelli: circa 500 pagine di testo
circa 1 milione	per confronto, dalle pagine dei produttori: GPT-6 Astra, Gemini 3.8 Flash

- Un milione di token, sul tokenizer attuale: circa **555.000 parole**, 2,5 milioni di caratteri
- «Ci sta» non vuol dire «lo usa bene»: la U di prima vale anche qui — **un contesto curato batte una finestra piena**