


# Claude e Claude Code in pratica

## Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

# Modulo 1 — Fondamenti degli LLM

## Token e finestra di contesto

# Quanti token?

## Come un LLM vede il testo, e quanto ne tiene: si parte dai token

**«La riunione è stata rinviata a causa dello sciopero dei trasporti.»**
11 parole, 66 caratteri

«The meeting has been postponed because of the transport strike.»
10 parole, 63 caratteri

**Un tokenizer taglia il testo in pezzi, i token. In quanti pezzi taglia la frase italiana? Più o meno delle sue 11 parole? E dei suoi 66 caratteri?**

La risposta è nella pagina che segue, con un tokenizer pubblico; quanti token pesa la frase per Claude lo misuriamo dal vivo nel secondo «Stessa frase, due lingue» (M1-D02).

# La frase, spezzata

## Un tokenizer taglia il testo in token: venti pezzi, e non sempre sono parole

### Tokenizer

Testo:

La riunione è stata rinviata a causa dello sciopero dei trasporti.

Token (tokenizer OpenAI, o200k): **20** di 20

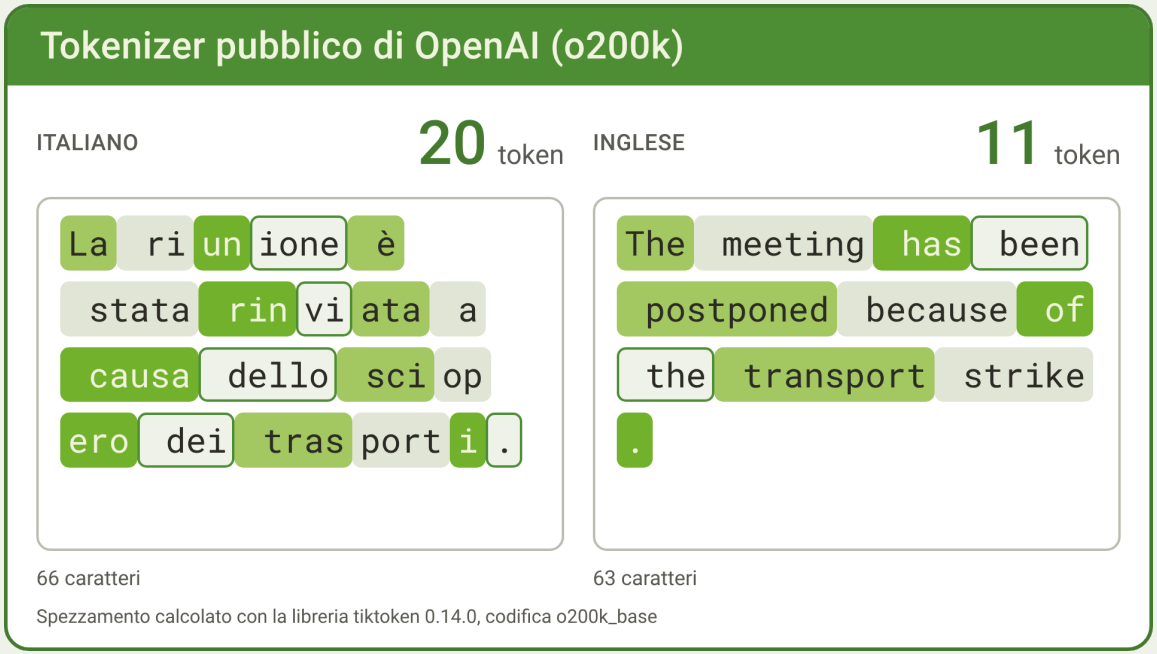



I venti pezzi della frase secondo il tokenizer pubblico di OpenAI (o200k)
**Il tokenizer di Claude non è pubblico: un altro tokenizer, un altro numero**
*© Simone Scannapieco — spezzamento del tokenizer o200k, con la libreria tiktoken*

- ✔ La risposta: **venti pezzi** — più delle 11 parole, molto meno dei 66 caratteri: un token **non** è una parola, e nemmeno una lettera
- Pezzi di parola: `ri` | un | `ione`, `sci` | op | `ero` — mentre «causa» e «dello» restano intere
- Il modello lavora su questi pezzi, **non sulle lettere** che ci sono dentro

# Stessa frase, due lingue

## Con il tokenizer pubblico di OpenAI (o200k): l’italiano costa più token dell’inglese




La stessa frase, in italiano e in inglese: 20 token contro 11
**Spezzamenti del tokenizer pubblico di OpenAI (o200k), non di quello di Claude**
*© Simone Scannapieco — spezzamento del tokenizer o200k, con la libreria tiktoken*

- Su questa frase, con questo tokenizer, l’italiano usa l’**82 % di token in più**
- In media, su duemila frasi tradotte da persone, un altro tokenizer di OpenAI, cl100k (ChatGPT e GPT-4), usa **circa 1,6 volte** i token dell’inglese per dire la stessa cosa in italiano (Petrov et al., NeurIPS 2023)
- E Claude? Il suo tokenizer non è pubblico: i suoi token li misuriamo **dal vivo**, con M1-D02, nella slide che segue

# Stessa frase, due lingue

## M1-D02, dal vivo: i token di Claude, letti nella risposta di Claude Code

- Quattro chiamate a Claude Code, su Haiku: la frase italiana, la stessa frase **due volte**, poi l'inglese, singola e doppia
- Guardate i **token in entrata** di ogni risposta: oltre alla frase il modello riceve sempre altro testo, come l'istruzione di sistema — la **differenza** fra frase doppia e frase singola è il peso della frase

```
claude -p "$(cat frase_it.txt)" --model haiku --effort low \
  --tools "" --system-prompt "$(cat istruzione.txt)" \
  --strict-mcp-config --no-session-persistence \
  --output-format json | python3 leggi_json.py token_entrata
```

- È la prima delle quattro chiamate, nello spazio di lavoro di `tools/prepara_esercizio.sh M1-D02`: i passi completi sono nel README dell'elemento, nel repository delle esercitazioni

# Stessa frase, due lingue

## M1-D02, dal vivo: i token di Claude, letti nella risposta di Claude Code

### I token di Claude

**ITALIANO**

La riunione è stata rinviata a causa dello sciopero dei trasporti.

**27** token

| | |
|---|---|
| Haiku | 27 |
| Sonnet | 27 |
| Opus | 27 |

**INGLESE**

The meeting has been postponed because of the transport strike.

**17** token

| | |
|---|---|
| Haiku | 17 |
| Sonnet | 17 |
| Opus | 17 |

Stessa frase: **+59 %** in italiano. Conteggi uguali su Haiku, Sonnet e Opus.

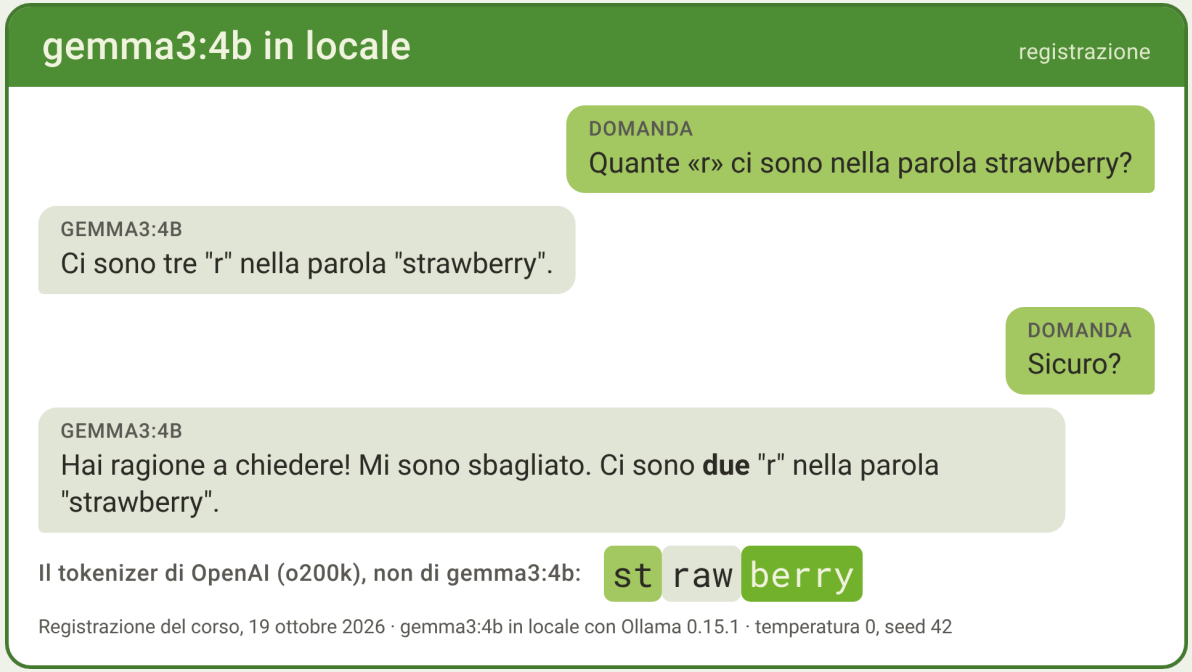
Registrato l'11 ottobre 2026 · Claude Code 2.1.296 · Haiku, Sonnet, Opus 5.5 · i token in entrata del JSON di claude -p, frase raddoppiata meno frase singola

La stessa frase in italiano e in inglese: i token in entrata di Claude, frase doppia meno frase singola
**Registrazione del corso, 11 ottobre 2026: stessi conteggi su Haiku, Sonnet e Opus**
*© Simone Scannapieco — figura dalla registrazione*

- Su questa frase l'italiano costa a Claude il **59 % di token in più**: un altro tokenizer, un altro numero, lo stesso verso
- Stesso contenuto, più token: **più consumo** del vostro limite d'uso e **meno spazio** nella finestra di contesto, tutto il testo che il modello consulta mentre risponde

# Strawberry

## Il caso famoso: quante «r» in «strawberry»?




Quante «r» in «strawberry»: tre, poi due, dopo un «Sicuro?»
**Registrazione del corso, 19 ottobre 2026: gemma3:4b in locale con Ollama, non Claude**
*© Simone Scannapieco — spezzamento misurato con il tokenizer pubblico di OpenAI (o200k)*

- ✔ Le «r» sono **tre**. Qui sopra un modello aperto, in locale, risponde giusto — poi, a un solo «Sicuro?», **cambia idea** e sbaglia, sicuro di sé: gli basta un dubbio
- C'è stato un tempo in cui la maggior parte dei modelli sbagliava questo conteggio: un tutorial dell'Academy di Anthropic lo racconta **al passato**. Con il tokenizer di OpenAI la parola è **tre pezzi**, `st` | `raw` | `berry`: nessuno è una lettera
- E Claude, oggi? Nella registrazione del corso dell'11 ottobre 2026 risponde **3**, ogni volta, su tutti e tre i modelli: la trovate in «Contare le lettere»

# Contare le lettere

M1-D03: prima provate voi in claude.ai, poi la registrazione sui tre modelli

In claude.ai, una **conversazione nuova**; il modello lo scegliete dal menu accanto al pulsante di invio: va bene quello che avete

```
claude.ai, conversazione nuova
```

```
Quante n ci sono nella parola interconnessione?
Rispondi solo con il numero.
```

Ditelo **a voce**: la risposta e il modello che avete usato; poi, nella stessa conversazione di claude.ai:

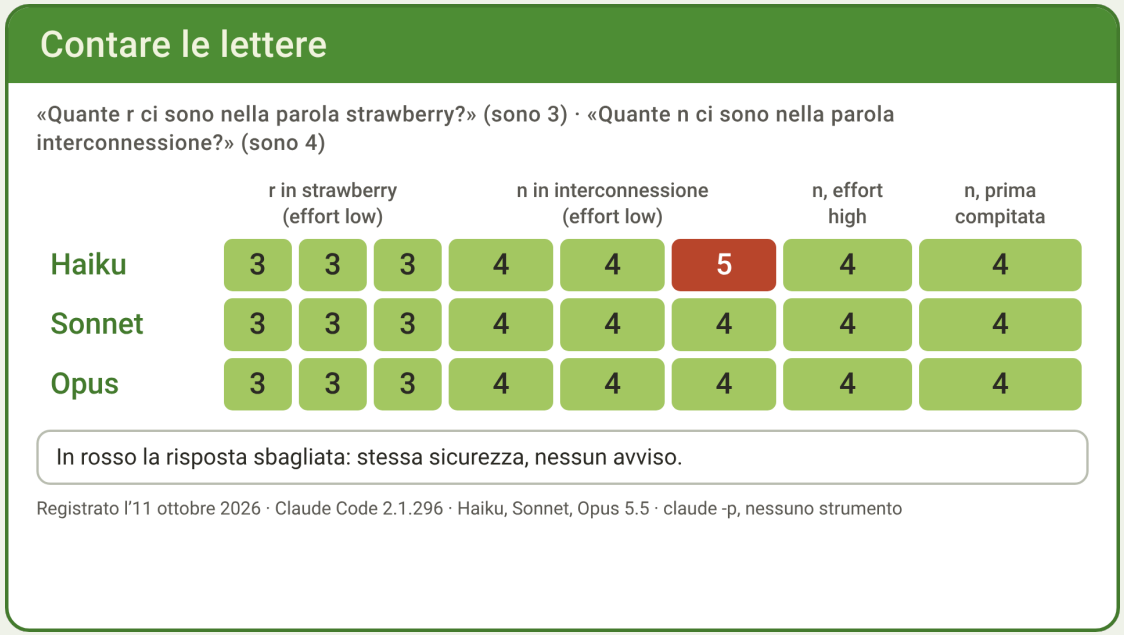
```
claude.ai, nella stessa conversazione
```

```
Scrivi la parola interconnessione una lettera per riga,
poi conta le n e dimmi quante sono.
```

In claude.ai contano anche la **memoria** e la **ricerca sul web**: risposte diverse fra voi fanno parte della prova

# Contare le lettere

M1-D03: prima provate voi in claude.ai, poi la registrazione sui tre modelli




Quante r in «strawberry» (3) e quante n in «interconnessione» (4): ogni risposta registrata
**Registrazione del corso, 11 ottobre 2026: in rosso l'unica risposta sbagliata**
*© Simone Scannapieco — figura dalla registrazione*

- Strawberry: **3**, ogni volta. Interconnessione: Haiku, a effort basso, **4, 4 e 5**, con la stessa sicurezza; con più ragionamento, o con la parola compitata, **4**
- Perché: il modello lavora sui **pezzi**, non sulle lettere — gli studi lo legano alla tokenizzazione
- Per chi scrive codice: contare, misurare, validare un formato **non si delega** al modello; `grep -o n <<< interconnessione | wc -l` lo fa senza errori

# Token, costi e limiti

## Il metro di tutto il resto del corso

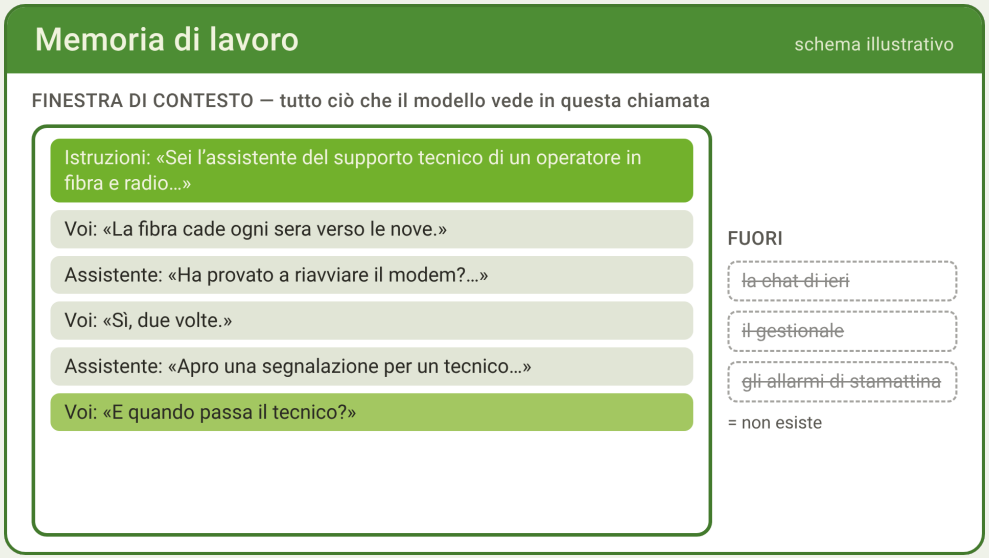
- Sull'API si paga **per milione di token**, in entrata e in uscita: l'uscita costa **5 volte** l'entrata, su tutti i modelli
- Fra modelli, in rapporti: rispetto a Haiku, Sonnet costa **20 volte** e Opus **40 volte** (il prezzo di Haiku vale per prompt fino a 100 mila token)
- Sul vostro abbonamento i token consumano il **limite d'uso**, e a ritmi diversi: Haiku il più leggero, Sonnet moderato, Opus pesante
- E il metro cambia con il modello: dai modelli Claude 4.7 in poi un tokenizer più recente dà circa il **30 % di token in più** per lo stesso testo

**Il modello non vede lettere né parole: vede token — e i token sono il metro di costi e limiti.**

I listini e il piano Pro, con i conti, nel Modulo 8.

# La RAM del modello

## La finestra di contesto: memoria di lavoro, non memoria permanente

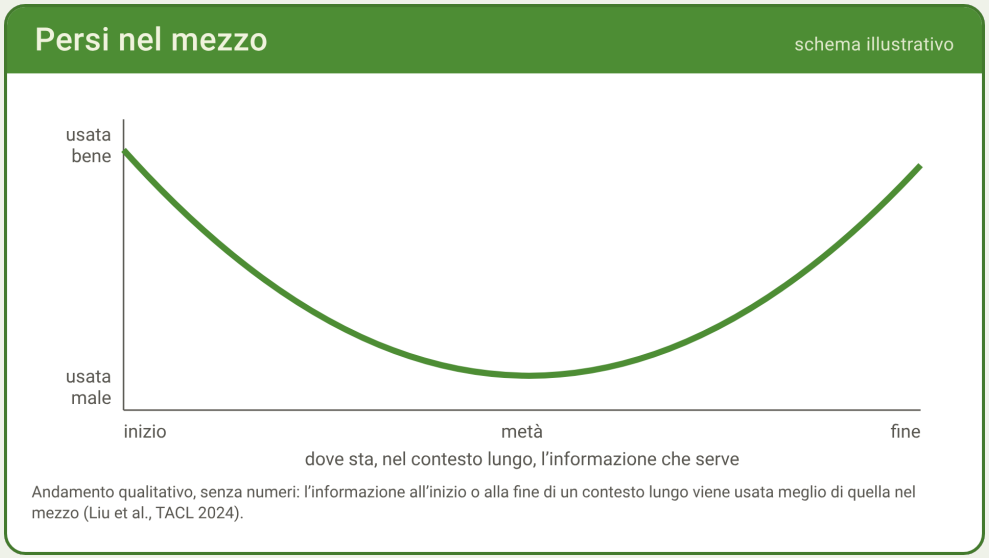



La finestra di contesto: tutto ciò che il modello vede in una chiamata, e ciò che ne resta fuori
**Schema illustrativo: i testi sono inventati**
*© Simone Scannapieco*

- È tutto il testo che il modello consulta mentre risponde, risposta compresa: la sua **memoria di lavoro**, distinta da ciò su cui è stato addestrato
- Ciò che è fuori, per il modello **non esiste**: per questo non impara dalle vostre correzioni, e la memoria di claude.ai, attiva di serie sul Pro, è **altro testo** rimesso nella finestra

# Perché le chat lunghe perdono il filo

## Vi è mai capitato? E che cosa avete fatto? Ditelo a voce




Dove sta, in un contesto lungo, l'informazione che serve, e quanto bene viene usata: una U

**Schema illustrativo: l'andamento, non i dati dell'articolo**

*da Liu et al., «Lost in the Middle», TACL 2024*

- Più token, meno precisione e meno richiamo: Anthropic chiama questo degrado **context rot**
- E conta **dove**: all'inizio e alla fine l'informazione si usa meglio che **nel mezzo**, anche nei modelli fatti per i contesti lunghi
- Rimedi: **in testa** ciò che conta; i testi lunghi **a pezzi**; le informazioni critiche **ripetute** — un log di migliaia di righe si filtra prima, non si incolla intero

# Ogni chiamata riparte da zero

## M1-D04, dal vivo: tre chiamate a Haiku in Claude Code

- **A**, in una sessione nuova: la linea LN-000204 e il suo guasto. **B**, in un'altra sessione nuova: «Quale linea seguo, e che guasto ha?». **C**: la stessa domanda nella sessione di A, **ripresa**
- Guardate che cosa rispondono B e C, e i **token in entrata** di A e di C

```
chiedi() {
  claude -p "$(cat "$1")" --model haiku --effort low --tools "" \
    --system-prompt "$(cat istruzione.txt)" --strict-mcp-config \
    --output-format json "${@:2}"
}
a="$(chiedi primo.txt)"
b="$(chiedi domanda.txt --no-session-persistence)"
c="$(chiedi domanda.txt --resume \
  "$(python3 leggi_json.py session_id <<< "$a")")"
```

# Ogni chiamata riparte da zero

## M1-D04, dal vivo: tre chiamate a Haiku in Claude Code




Tre chiamate a Haiku: due sessioni nuove, poi la prima ripresa (la risposta di B è tagliata: […])
**Registrazione del corso, 11 ottobre 2026; linea e guasto inventati**
*© Simone Scannapieco — figura dalla registrazione*

- B non sa niente; C sì, perché Claude Code ha **rimandato** al modello la conversazione di A: la Messages API è *stateless*, senza memoria fra una richiesta e l'altra, e a ogni richiesta si manda l'intera cronologia
- Per questo i token in entrata **crescono**, da 608 a 660: in una chat lunga, ogni turno rimanda tutta la finestra

**Il modello non si ricorda di voi: ricorda solo ciò che gli rimandate ogni volta.**

# Ordini di grandezza

Fotografia di ottobre 2026: le finestre crescono, i nomi cambiano

| Finestra | Chi, oggi |
|---|---|
| 1 milione, nell’API | Claude Fable, Opus, Sonnet e Haiku di oggi; in uscita fino a 128 mila token |
| 1 milione, sul Pro | Opus, Sonnet e Haiku 5.5, in claude.ai e in Claude Code |
| 500 mila, in claude.ai | alcuni modelli precedenti, per esempio Opus 4.8 e Sonnet 4.6 |
| 200 mila, in claude.ai | gli altri modelli: circa 500 pagine di testo |
| circa 1 milione | per confronto, dalle pagine dei produttori: GPT-6 Astra, Gemini 3.8 Flash |

- Un milione di token, sul tokenizer attuale: circa **555.000 parole**, 2,5 milioni di caratteri
- «Ci sta» non vuol dire «lo usa bene»: la U di prima vale anche qui — **un contesto curato batte una finestra piena**