

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

Modulo 5 — Skills

Quando una skill batte un system prompt lungo

Che cosa dice Anthropic, e di che cosa

Nelle pagine lette nessuna frase la risolve: ognuna parla di una cosa precisa

Una skill è una cartella con uno `SKILL.md`: nel contesto sta la sua descrizione, il contenuto completo si carica quando viene invocata. Quando batte un system prompt lungo?

Fra le pagine di Anthropic lette per il corso, **nessuna** mette a confronto una skill e un system prompt lungo con queste parole. Le frasi più vicine, e di che cosa parla ciascuna:

la frase	di che cosa parla
«Unlike prompts (conversation-level instructions for one-off tasks), Skills load on demand»	i **prompt** di una conversazione
«frequently outperformed both the one-prompt-for-everything design and the subagent design on quality»	un **agente**, in diversi deployment enterprise
«Progressive disclosure prevents context bloat … without requiring all of the context to be immediately loaded into one long system prompt»	lo stesso articolo: chi costruisce un **agente**
«Then: Put it all upfront … Now: Use progressive disclosure»; «you will likely never modify this»	il system prompt **di Claude Code**
«Appending the system prompt can have a higher context cost compared to other methods of passing instructions.» «the more instructions you provide using this method, the less strictly Claude will follow them»	l'**append** al system prompt
«A long release procedure sitting in a skill doesn't weigh on your unrelated bug fix the way it would in CLAUDE.md.»	`CLAUDE.md`, che non fa parte del system prompt

Dalla panoramica delle skill, da un articolo sugli agenti, dal blog di Claude, da «Steering Claude Code» e dalle best practice

Il confronto diretto lo facciamo noi, con una misura: lo stesso testo in tre posti

M5-D01 Lo stesso testo in tre posti

Demo del docente in Claude Code: una domanda che del testo non ha bisogno

- Dalle best practice di Claude Code: «A long release procedure sitting in a skill doesn't weigh on your unrelated bug fix the way it would in CLAUDE.md.»
- Da «Steering Claude Code»: «Appending the system prompt can have a higher context cost compared to other methods of passing instructions.» Due **confronti**, esecuzione per esecuzione
- Il testo: tre procedure dell'assistenza del corso, **187 righe, 10.859 caratteri**, dentro i limiti dello standard Agent Skills per il corpo: sotto le 500 righe e i 5.000 token raccomandati

braccio	dove sta il testo
`skill`	il corpo di `.claude/skills/procedure-assistenza/SKILL.md`
`claude_md`	`CLAUDE.md`
`append`	`testo.md`, passato all'avvio con `--append-system-prompt-file`
`niente`	da nessuna parte

- In ogni braccio una sessione nuova di `claude -p`, Sonnet, effort low, senza strumenti consentiti, e la stessa domanda: «Rispondi solo: ok». Guardate i token della **prima richiesta**:

```
m5_skills/s4_skills/m5_3_skill_o_system_prompt/\
M5-D01_stesso_testo_tre_posti/demo/in_classe.sh \
  ~/corso-claude-code/M5-D01
```

- **Indovinate, a voce**: lo stesso testo in tre posti, e una domanda che non ne ha bisogno: quanti token in più in ciascun posto?

M5-D01 Lo stesso testo in tre posti

Demo del docente in Claude Code: una domanda che del testo non ha bisogno

La registrazione del corso: tre esecuzioni, sei chiamate ciascuna. Il controllo legge gli stream, e di ogni braccio la **prima richiesta**

esecuzione	niente	skill	claude_md	append
1	17.271	17.395	22.251	22.113
2	17.271	17.395	22.251	22.113
3	17.271	17.395	22.251	22.113
sopra niente, in ciascuna		**+124**	**+4.980**	**+4.842**

La prima richiesta di ogni braccio, in token: i valori che il controllo ha stampato, in tabella
Registrazione del corso, 3 novembre 2026, Claude Code 2.1.317, Sonnet, effort low

La risposta: **+124** token come skill, cioè la sua descrizione; **+4.980** in CLAUDE.md e **+4.842** in append, cioè il testo. Dalla tabella della documentazione: CLAUDE.md, «Every request»; le skill, «Low (descriptions every request)»

Come si conta: il primo messaggio dell'assistente, i tre campi di usage sommati. Dalla pagina sul prompt caching: «total_input_tokens = cache_read_input_tokens + cache_creation_input_tokens + input_tokens». E dell'append, da «Steering Claude Code»: «prompt caching reduces this cost after the first request in a session»

M5-D01 Lo stesso testo in tre posti

Demo del docente in Claude Code: una domanda che del testo non ha bisogno

```
i verdetti, a capo per la slide: «[…]» segna un taglio
```

```
Skill contro CLAUDE.md, «doesn't weigh … the way it would in
  CLAUDE.md»: […] confermata 3 su 3
Skill contro append, «can have a higher context cost»: […]
  confermata 3 su 3
[…]
Chiamate a Skill sulla domanda, nel braccio della skill: 0 su 3.
```

- Append contro `CLAUDE.md` è un **dato**: «append meno claude_md -138». Nessuna delle due frasi li mette in ordine
- Poi, nel braccio della skill, `/procedure-assistenza Qual è la velocità massima in upload dell'offerta Casa Radio?`, e al turno dopo «E in download?». Il corpo «enters the conversation as a single message and stays there across later turns»

esecuzione	non invocata	invocata	turno dopo
1	17.395	22.388 (+4.993)	22.532 (+5.137)
2	17.395	22.388 (+4.993)	22.540 (+5.145)
3	17.395	22.388 (+4.993)	22.551 (+5.156)

La prima richiesta, in token: i valori che il controllo ha stampato, in tabella, come dati
Registrazione del corso, 3 novembre 2026, Claude Code 2.1.317, Sonnet, effort low

Che cosa guadagna e che cosa perde

I tre posti a confronto, e il prezzo di una skill

	skill	`CLAUDE.md` alla radice	append
quando entra	nome e description all'avvio, il corpo all'invocazione	all'avvio, e resta per tutta la sessione	all'avvio, per quel solo avvio di `claude`
costo di contesto	«Low. Full body loads only when invoked»	«High. Every line costs tokens whether relevant or not»	«Moderate. Cached after first request in a session»
alla compattazione	i corpi tornano: 5.000 token per skill, 25.000 in tutto, le più vecchie cadono per prime	sopravvive	«Never compacted»: il system prompt continua ad applicarsi

Dall'articolo «Steering Claude Code», dalla pagina sulla finestra di contesto e dal glossario

- Che cosa **guadagna**: il corpo resta fuori finché non serve, e un testo lungo «costs almost nothing until you need it»
- Che cosa **perde**: «Once a skill loads, its content stays in context across turns, so every line is a recurring token cost.» E può non scattare: con troppe funzioni, «skills may not trigger correctly»; e accorciare una description «can stop the skill triggering»
- E l'append: vale per quel solo avvio, e «preserves the default tool guidance, safety instructions, and coding conventions, so you only supply what differs»
- La **lettura del corso**, dalla misura di M5-D01 e da queste frasi: una skill batte un system prompt lungo quando il testo serve a volte (+124 token contro +4.842 in append, sulla domanda che non ne ha bisogno), non quando deve valere sempre

Dove va che cosa

La decisione, nelle parole di Anthropic

che cosa	dove	perché
Claude deve saperlo sempre: convenzioni, comandi di build, struttura del progetto	`CLAUDE.md`	«if Claude should always know it»
Ogni risposta in una voce, lunghezza o formato	**output style**	«Every response in a certain voice, length, or format»
Materiale che serve a volte, o un flusso da avviare con `/nome`, da vedere e guidare passo per passo	**skill**	«reference material Claude needs sometimes»; «see and steer each step»
Un compito laterale, come una ricerca profonda o un'analisi di log	**subagent**	«would clutter your main conversation»
Una regola che deve valere ogni volta	**hook**	«If a rule must hold every time, make it a hook rather than a prompt instruction.»

Da «Extend Claude Code», dalla pagina sugli output style e da «Steering Claude Code»

- «An instruction like "never edit .env" in CLAUDE.md or a skill is a request, not a guarantee.» L'hook «Fires on its event without Claude deciding»; con la skill «Claude interprets the instructions; outcome can vary». Se Claude salta una regola che deve valere sempre: «move the rule into a hook»
- Un segnale: «A 30-line procedure in CLAUDE.md. Procedures belong in skills.»

Ciò che serve a volte va in una skill, ciò che serve sempre in `CLAUDE.md`, ciò che deve valere ogni volta in un hook.

Anche una skill costa

Una riga a ogni turno, e due comandi per leggerla

- «Every skill in the skill listing adds to your context on every turn, whether or not Claude ever uses it.» E l'elenco ha un tetto: `skillListingBudgetFraction`, di serie 0,01, «reserves 1% of the context window»
- `/skill-doctor`: «what each of your skills costs and how often it gets used». Sulla skill della prima esercitazione del modulo:

skill	source	context	7d tokens	uses	last used
`riassunto-modifiche`	projectSettings	~80	-	0×	never

Registrazione del corso, 3 novembre 2026, Claude Code 2.1.317, nessuna chiamata al modello

`la sua nota, a capo per la slide: «[…]» segna un taglio`

```
context = this skill's one-line listing […], included every turn
(dash = not in the current listing, costs nothing; full SKILL.md
loads only when it runs)
```

- Sul Pro, `/usage` divide l'utilizzo per skill, subagent, plugin e server MCP; e la cifra di costo della sessione «isn't relevant for billing purposes»
- La scala: nella versione 2.1.234 la skill integrata `claude-api` è scesa «from ~200k+ tokens to ~25k by loading reference docs on demand»