

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

Modulo 6 — Projects e Context Engineering

Perché il contesto è tutto

Il documento che nessun modello ha letto

M6-D01, demo del docente in Claude Code: prima senza il documento

- La **carta dei servizi** di CiaspoLink, l'operatore inventato del corso: sette articoli scritti per il corso, dati sintetici. **Nessun modello l'ha mai letta**. L'Art. 4 dice i tempi degli interventi sugli apparati in quota
- Due bracci, una sessione nuova di `claude -p` ciascuno, con Read, Glob e Grep, Sonnet ed effort low: `senza`, una cartella **senza la carta**; `con`, subito dopo, la carta importata dal `CLAUDE.md`. La domanda è la stessa:

domanda.txt, uguale nei due bracci, a capo per la slide

```
Entro quanti giorni lavorativi va fatto un intervento su un ponte
radio in quota?
```

```
m6_projects_context/s5_projects_context/\
m6_2_il_contesto_e_tutto/M6-D01_documento_mai_letto/\
demo/in_classe.sh ~/corso-claude-code/M6-D01
```

- Da «Reduce hallucinations»: anche i modelli più avanzati, come Claude, «can sometimes generate text that is factually incorrect»; fra le tecniche, «Explicitly give Claude permission to admit uncertainty.» La nostra domanda **non lo fa**: è come la farebbe chiunque
- Guardate se Claude **cerca** la carta, e se risponde con le **cifre** dell'Art. 4

Il documento che nessun modello ha letto

M6-D01, demo del docente in Claude Code: prima senza il documento

La registrazione del corso: tre esecuzioni per braccio. Senza la carta, in tutte e tre Claude ha **cercato** nella cartella, con Grep e poi con Glob, e Grep ha dato «nessun risultato». La prima:

```
senza-1, le righe del controllo: «[…]» segna un taglio

senza-1 (senza la carta)
  strumenti:
    Grep «ponte radio|ponti radio» in .: nessun risultato
    Grep «in quota|giorni lavorativi» in .: nessun risultato
    Glob «**/*» in .: 27 righe
  […]
  le cifre dell'Art. 4, 5 e 9 giorni lavorativi: no
```

Le cifre dell'Art. 4: **no**, in tutte e tre. Dalle risposte: «Non so rispondere con certezza.» «… preferisco non darle un numero inventato.» «Non conosco nemmeno un termine standard valido in generale.»

La frase di Anthropic dice «can sometimes»: tre esecuzioni senza una cifra inventata non la mettono in discussione. Dicono che cosa ha fatto Claude **qui**: ha cercato, non ha trovato, e l'ha detto

Registrazione del corso, 7 novembre 2026, Claude Code 2.1.319, Sonnet, effort low

Ora glielo facciamo leggere

M6-D01: la stessa domanda, con la carta importata dal `CLAUDE.md`

- Stessa domanda, stesso modello, stessi strumenti. Nella copia del braccio con, in più, la carta in `docs/carta-servizi.md` e un `CLAUDE.md` di tre righe che la importa:

`con-la-carta/CLAUDE.md`

```
# CiaspoLink

- La carta dei servizi di CiaspoLink: @docs/carta-servizi.md
```

- Dalla documentazione: «CLAUDE.md files can import additional files using @path/to/import syntax.»
- La frase che la demo mette alla prova, dalla lezione «Working Memory» dell'Academy: «The model doesn't learn from your corrections. It only responds to **what's currently in context**.» La demo rifà in Claude Code la prima delle tre prove della lezione: «Probe 1: Cold start vs. context.»
- Guardate se Claude cerca ancora, e con quali **cifre** e quale **articolo** risponde

Ora glielo facciamo leggere

M6-D01: la stessa domanda, con la carta importata dal `CLAUDE.md`

`con-1, a capo per la slide: «[…]» segna un taglio`

```
con-1 (con la carta, importata dal CLAUDE.md)
  strumenti: nessuno
  risposta:
    Secondo l'Art. 4 della Carta dei servizi, dipende dal periodo:
    - **da maggio a ottobre**: entro **5 giorni lavorativi**;
    - **da novembre ad aprile**: entro **9 giorni lavorativi**,
    perché la squadra sale con i […]
  le cifre dell'Art. 4, 5 e 9 giorni lavorativi: sì
  i numeri della risposta, fuori da citazioni e date: 5, 9
  articoli citati: Art. 4, Art. 5
```

- Le citazioni, **una dimostrazione** dello script: cerca nella carta ogni articolo citato, e lì i numeri della risposta. In tutte e tre: «i numeri della risposta negli articoli citati: tutti»
- La coppia, in ogni esecuzione: «confermata (con la carta 5 e 9 giorni; senza, no)». In tutto, **«confermata 3 su 3»**
- Come dati, la prima richiesta: **+1.130**, +1.135, +1.135 token; un import non ne riduce il costo: «Imports … don’t reduce its context cost», dalla documentazione. È cambiato **solo il contesto**

Registrazione del corso, 7 novembre 2026, Claude Code 2.1.319, Sonnet, effort low

Perché la prima risposta non c’era?

Una domanda a voce, tre risposte possibili

Perché la prima risposta non aveva i giorni? Il modello, i dati o il prompt?

a il modello **b** i dati **c** il prompt

La risposta: **(b) i dati**. Lo stesso modello, la stessa domanda; in più, nel contesto, la carta

- (a) La carta non l’ha letta **nessun modello**: è scritta per il corso. (c) La domanda era la stessa, parola per parola: la differenza è un **documento**, non un’istruzione
- Il tutorial dell’Academy: quando un modello produce informazioni sbagliate, «it’s usually a side-effect of missing, incorrect, or low-quality context». Qui la risposta non era sbagliata: **mancava**, come mancava il documento
- Un **RAG embrionale**: trovare il documento, metterlo nel contesto, far rispondere con la fonte. E con la fonte la risposta **si controlla**: «Make Claude’s response auditable by having it cite quotes and sources for each of its claims», dalla guida sulle allucinazioni

Il modello non conosce i vostri documenti: il problema non è il modello, è il collegamento.

Che cos’è il contesto

Nelle parole di Anthropic: i token che il modello ha davanti, e chi li sceglie

- Il **contesto**, per «Effective context engineering for AI agents»: «the set of tokens included when sampling from a large-language model (LLM)»
- Il **context engineering**: «the art and science of curating what will go into the limited context window». E non si fa una volta sola: la scelta si ripete «each time we decide what to pass to the model»
- Il prompt ne è una **piccola parte**. Dal blog di Claude: «Much of your context is assembled from your system prompt, Skills, CLAUDE.md files, memory, and other sources.»
- Una risorsa **finita**: «a finite resource with diminishing marginal returns». Ogni token in più consuma un po’ dell’«attention budget» del modello
- Lo scopo: «the smallest possible set of **high-signal tokens** that maximize the likelihood of some desired outcome»

Il problema ha due facce

Ciò che il modello non sa, e ciò che non può sapere

- Ciò che il modello **non sa**: ciò che è venuto dopo i suoi dati di addestramento, il punto del Modulo 1. Dal centro assistenza: «These models may not be aware of events or information that occurred after their respective cutoff dates.»
- Ciò che **non può sapere**: ciò che non è mai stato pubblicato. La carta di CiaspoLink, le procedure di un team, le sue decisioni
- E mettere tutto nel contesto, sempre? Tre limiti, nelle pagine di Anthropic:
  - ogni richiesta **lo reinvia**: «Every request sends the whole conversation», dalle best practice. La carta della demo pesava già 1.130 token in più alla prima richiesta
  - più contesto non è **di per sé** meglio: «more context isn't automatically better», dalla pagina sulla finestra di contesto
  - al crescere dei token, «accuracy and recall degrade, a phenomenon known as **context rot**»

Quasi mai serve addestrare: serve collegare

Tre vie per dare al modello ciò che non ha, nelle pagine di Anthropic

↔ Le due facce, in una riga: ciò che il modello **non sa**, venuto dopo il suo addestramento, e ciò che **non può sapere**, mai pubblicato. Le vie per darglielo sono tre:

la via	che cosa fa	quando, per Anthropic
fine-tuning	adatta il modello «to a specific domain, task, or writing style»	la Claude API, per ora, **non lo offre**: «does not currently offer fine-tuning»
tutto nel contesto	i documenti nella finestra di contesto, come la carta nella demo	sotto i 200.000 token, circa 500 pagine: «you can just include the entire knowledge base in the prompt» (settembre 2024)
recupero (RAG)	una base di conoscenza esterna, o dei documenti, «passed into the context window»	le basi «that don't fit within the context window»; informazioni aggiornate, conoscenza di dominio, **citazione delle fonti**

Dal glossario della piattaforma e da «Introducing Contextual Retrieval»

🔍 In Claude Code, dal blog di Claude: nelle prime versioni interne un database vettoriale indicizzava il codice, ma «Claude was given this context instead of finding the context itself». Poi Grep: «we could let it search for files and **build context itself**»

💡 E sugli agenti: «For many applications, however, optimizing single LLM calls with **retrieval and in-context examples** is usually enough.»