

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

Modulo 6 — Projects e Context Engineering

Il budget del contesto

Che cosa costa che cosa

Che cosa entra nel contesto, quando, e quanto pesa

Il `CLAUDE.md`, le skill, i server MCP, i subagent, gli hook: non costano allo stesso modo, né nello stesso momento. La tabella della documentazione:

	quando, e che cosa entra	**il costo**
`CLAUDE.md`	all'avvio della sessione, ogni file per intero	«Every request»
skill	all'avvio le descrizioni, il contenuto quando si usa	«Low (descriptions every request)»
server MCP	all'avvio i nomi degli strumenti, gli schemi completi su richiesta	«Low until a tool is used»
subagent	quando parte, con un contesto nuovo (o, per un fork, la conversazione principale)	«Isolated from main session»
hook	quando scatta: niente, gira fuori	«Zero, unless hook returns additional context»

Dalla pagina «Extend Claude Code»

E le skill, anche quelle che non si usano: «Every skill in the skill listing adds to your context on every turn, whether or not Claude ever uses it.»

Che cosa costa che cosa

Che cosa entra nel contesto, quando, e quanto pesa

Una sessione vera: `/context all` nell'esercitazione «Che cosa vede Claude», dopo un `CLAUDE.md` di due righe. Divide il contesto per categoria:

`dopo.md, righe scelte: «[…]» segna un taglio`

```
**Model:** claude-sonnet-5-5
**Tokens:** 13.2k / 1m (1%)
[…]
| Category | Tokens | Percentage |
|----------|--------|------------|
| System prompt | 2.4k | 0.2% |
| System tools | 8.4k | 0.8% |
| System tools (deferred) | 13.8k | 1.4% |
| Memory files | 71 | 0.0% |
| Skills | 2.3k | 0.2% |
| Messages | 10 | 0.0% |
| Free space | 953.8k | 95.4% |
| Autocompact buffer | 33k | 3.3% |
```

Memory files: 71 token, il `CLAUDE.md` di due righe. La finestra, nella registrazione del corso: **1m**

Registrazione del corso, 7 novembre 2026, Claude Code 2.1.319, Sonnet: `/context all` in `claude -p`

Il costo di una riga

Un commento, lo stesso testo visibile, un import: la misura

- Dal blog di Claude: «Every turn resends the whole context, so a turn costs more as the context grows, even with a warm cache.» Il `CLAUDE.md` compreso
- Nella demo M6-D02, «Rispondi solo: ok», senza strumenti, con quattro `CLAUDE.md`: un titolo e una riga (`base`); gli stessi, più una procedura di 2.188 byte in un commento a blocco (`commento`), visibile (`inline`) o importata con `@` (`import`)

`la prima richiesta dei quattro bracci, a capo per la slide`

```
Come dato, la prima richiesta dei bracci di costo, «Rispondi solo:
  ok»: base 2.365 token; commento 2.365 token; inline 3.316 token;
  import 3.389 token.
Come dato, il commento a blocco sul braccio base: +0 token; lo
  stesso testo visibile (inline): +951.
Come dato, l'import contro lo stesso testo incollato: +73 token
  (import ≥ inline: sì).
```

- Il commento: **+0**, perché «Block-level HTML comments … are stripped before the content is injected into Claude's context.» Visibile: **+951**. Importato, quanto incollato, e qui 73 in più: «Imports … don't reduce its context cost»
- Sono dati: nessuna delle frasi dà una soglia in token

Registrazione del corso, 7 novembre 2026, Claude Code 2.1.319, Sonnet, effort low

Il budget, con una finestra da 1M

Esaurirla capita di rado: restano l’attenzione, l’uso e il rumore

- In Claude Code, sui piani a pagamento, Pro compreso, i modelli 5.5 hanno una finestra di contesto di **1M token**: «Claude Opus 5.5 | 1M tokens … Claude Sonnet 5.5 | 1M tokens … Claude Haiku 5.5 | 1M tokens»
- Dalle best practice: «With a 1M-token window on most current models and compaction near the top of it, you’ll **rarely run out of context**.»
- Fra i consigli che la stessa pagina dà per **superati**: «The context window is your main constraint, manage it aggressively». Perché: «Most current models have a 1M-token window and compaction happens on its own»: la compaction, la compattazione del Modulo 4, avviene da sé

- E allora, che cosa resta da gestire?

Il budget, con una finestra da 1M

Esaurirla capita di rado: restano l'attenzione, l'uso e il rumore

- L'**attenzione**: «LLMs have an "attention budget" that they draw on when parsing large volumes of context. Every new token introduced depletes this budget by some amount». E conta **dove**: «models reliably process information at the beginning and end of long inputs but may omit findings from middle sections», dalla guida d'esame di Claude Certified Architect. È il **lost in the middle** del Modulo 1; l'Academy ne fa una prova, «Probe 2: Lost in the middle»
- L'**uso**: «a one-line question in a session that has been open all day still draws usage for the whole conversation»
- Il **rumore**: «Too much can fill up your context window, but it can also add noise that makes Claude less effective»
- Le mosse. `/clear` fra un compito e l'altro: «It costs nothing, and it means the next task doesn't keep paying for the previous one's history.» Un compito nuovo, una **sessione nuova**. Le letture grandi a un subagent, «so the file contents stay in its context window, not yours». Un hook che filtra un output: «a hook can grep for ERROR and return only matching lines»

Il budget non è lo spazio: è l'attenzione, l'uso e il rumore.

M6-D04 Una modifica a sessione avviata, e dopo /compact

Demo del docente in Claude Code: una sessione sola, e un file che cambia da fuori

Sul `CLAUDE.md` della radice, la pagina «How Claude Code uses prompt caching»: «Editing them mid-session does not invalidate the cache, but the edit also doesn't apply. … The new content loads on the next /clear, /compact, or restart.»

Tre sessioni, ognuna **un solo processo** di `claude -p`, Sonnet, effort low, che riceve i messaggi uno alla volta, come una sessione che tenete aperta voi:

sessione	strumenti	i cinque passi
`compact`	nessuno	la domanda; il `CLAUDE.md` riscritto da fuori, con una parola nuova; la domanda; `/compact`; la domanda
`clear`	nessuno	gli stessi, con `/clear` al posto di `/compact`
`regola`	solo Read	leggi `src/a.php`, che carica una regola con `paths`; `/compact`; elenca le parole; leggi `src/a.php`; elenca

La domanda: «Senza leggere file, qual è la parola in codice delle tue istruzioni di progetto? Rispondi solo con la parola.»

```
m6_projects_context/s5_projects_context/\
m6_6_budget_del_contesto/M6-D04_modifica_e_compact/\
demo/in_classe.sh ~/corso-claude-code/M6-D04
```

Indovinate, a voce: dopo `/compact`, quale delle tre parole ricorderà Claude? Quella di prima, quella nuova, o quella della regola?

M6-D04 Una modifica a sessione avviata, e dopo /compact

Demo del docente in Claude Code: una sessione sola, e un file che cambia da fuori

La registrazione del corso, tre esecuzioni. La prima sessione `compact`, passo per passo:

passo	che cosa	risposta	caricamenti
1	la domanda	«PRIMA-EJOTFM»	`session_start` `CLAUDE.md`
2	`CLAUDE.md` riscritto da fuori, con DOPO-GOPGUE		nessuno
3	la domanda	«PRIMA-EJOTFM»	nessuno
4	`/compact`	compattato, 2.512 → 881 token; nel riassunto: prima sì; nuova no	nessuno
5	la domanda	«DOPO-GOPGUE»	`compact` `CLAUDE.md`

compact, 1: i passi, come il controllo li ha stampati, in tabella

Registrazione del corso, 7 novembre 2026, Claude Code 2.1.319, Sonnet, effort low

- **La risposta**: dopo `/compact`, la parola **nuova**, 3 su 3, anche se il riassunto portava quella di prima. E la parola della regola c'era ancora, 3 su 3: la pagina seguente
- Il controllo: «Una modifica a CLAUDE.md a sessione avviata non si applica: confermata 6 su 6»; «Dopo /compact il CLAUDE.md della radice si rilegge dal disco: confermata 6 su 6»; il contenuto nuovo al `/compact` successivo e al `/clear` successivo: «confermata 3 su 3» tutti e due
- Il motivo `compact` del registro: «The "compact" value fires when instruction files are re-loaded after a compaction event»

M6-D04 Una modifica a sessione avviata, e dopo /compact

Demo del docente in Claude Code: una sessione sola, e un file che cambia da fuori

- La sessione `regola`: il primo Read di `src/a.php` carica la regola, `path_glob_match`: «La regola con paths si carica quando Claude legge un file che corrisponde: confermata 3 su 3». Poi `/compact`, l'elenco delle parole, un secondo Read, un altro elenco. Dopo le garanzie, il controllo stampa un **reperto**:

```
il reperto del controllo, a capo per la slide

Reperto: la pagina dice «Rules with paths: frontmatter | Claude
  Code reloads them on demand» e «Path-scoped rules and nested
  CLAUDE.md files load into message history when Claude reads,
  writes, or edits their trigger file, so compaction summarizes
  them away» (https://code.claude.com/docs/en/context-window); in
  queste esecuzioni, del 7 novembre 2026, con Claude Code 2.1.319,
  in una sessione sola: nessun caricamento della regola dopo
  /compact al Read di un file che corrisponde, 3 su 3, e la parola
  della regola nella risposta subito dopo /compact, 3 su 3.
```

- Come dati, in tutte e tre: nel riassunto della compaction «radice sì; regola sì»; e «Come dato, i caricamenti della regola dopo /compact: nessuno.» Il reperto non è un verdetto: dice che cosa hanno trovato queste esecuzioni, con la data e la versione

Registrazione del corso, 7 novembre 2026, Claude Code 2.1.319, Sonnet, effort low

Guidare la compaction

Che cosa tiene il riassunto, e come dirglielo

- Dalla lezione «Steering long sessions» dell'Academy: «So don't just run /compact on its own. Add instructions after the command to tell Claude how to summarize.» Ciò che scrivete dopo il comando: «That's your steering wheel for context.»
- Oppure nel `CLAUDE.md`, dalla documentazione: «To control what's preserved during compaction, add a "Compact Instructions" section to CLAUDE.md or run /compact with a focus»
- Che cosa si può perdere: «The summary keeps your requests and key code snippets, but detailed instructions from early in the conversation may be lost.» E dal blog di Claude: «A compaction in the middle of a debugging session can drop the one log line that mattered.»
- Che cosa resta: «A long run fills the context window, and Claude Code then summarizes older turns. A list in a file survives that»
- E ancora: `/btw`, una domanda a margine «without adding to the conversation»; la status line, con la percentuale di finestra usata; nella Claude API il context editing e il memory tool