

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

Modulo 7 — Anatomia, conversazione e strumenti

Anatomia di un assistente

Il system prompt è configurazione

Che cosa scrive chi costruisce l’assistente: ruolo, lingua, che cosa fare

- Un assistente ha quattro parti: system prompt, strumenti, conoscenza e guardrail. Questa parte del modulo apre la prima, il **system prompt**, con l’assistente di CiaspoLink, il fornitore di connettività inventato del corso
- Per la Messages API è un modo di dare a Claude **contesto e istruzioni**, come un obiettivo o un ruolo specifico. Lo scrive chi costruisce l’assistente, non il cliente: è **configurazione**, come un file di configurazione
- Il **ruolo**: impostarlo nel system prompt orienta comportamento e tono di Claude per il vostro caso d’uso, e basta anche una sola frase
- La **lingua** della risposta: in produzione va dichiarata esplicitamente, e il posto più affidabile è il system prompt
- **Che cosa fare**: per il formato, dire a Claude che cosa fare invece di che cosa non fare

Il system prompt è configurazione: si versiona e si prova come il codice.

M7-D01 Cambia solo il system prompt

Demo del docente in Claude Code: lo stesso messaggio, due system prompt

- La frase alla prova, dalla Messages API: «A system prompt is a way of providing context and instructions to Claude, such as specifying a particular goal or role.»
- Lo stesso messaggio di una cliente inventata; cambia **soltanto il system prompt**:

`messaggio.txt, a capo per la slide`

```
Buongiorno, sono Giulia Campione. La fibra di casa continua a
cadere e il router ha una luce rossa fissa. L'ho già spento e
riacceso due volte. Che cosa posso fare?
```

`system-generico.md, il system prompt neutro`

```
Sei un assistente disponibile e rispondi in italiano.
```

`system-ciaspolink.md, a capo per la slide`

```
Sei l'assistente clienti di CiaspoLink, operatore di connettività
in fibra e radio nelle valli del Trentino, e dai del lei al
cliente. Rispondi al massimo in tre righe.
```

M7-D01 Cambia solo il system prompt

Demo del docente in Claude Code: lo stesso messaggio, due system prompt

- **Indovinate, a voce**: con una riga in più nel system prompt, la risposta alla stessa domanda diventa **più lunga o più corta**?
- Ogni chiamata è una sessione nuova di `claude -p`, su Sonnet con effort low, senza strumenti e da una cartella vuota. Le due chiamate differiscono solo nel file di `--system-prompt-file`, che **sostituisce l'intero prompt predefinito** con il suo contenuto. Il comando, dalla cartella `esercitazioni`:

```
m7_assistenti_llm/s5_anatomia_e_strumenti/m7_2_anatomia/\
M7-D01_cambia_il_system_prompt/demo/in_classe.sh \
  ~/corso-claude-code/M7-D01
```

- Guardate quante **righe** ha ogni risposta e i **token della prima richiesta**: il system prompt, il messaggio e ciò che Claude Code aggiunge da sé
- Alla fine il controllo, `controlla_sistema.py`, legge gli stream delle due chiamate e stampa righe, token e il confronto

M7-D01 Cambia solo il system prompt

Demo del docente in Claude Code: lo stesso messaggio, due system prompt

```
parte 1, le righe del controllo, a capo per la slide

La riga «al massimo tre righe», che il secondo system prompt
nomina (una soglia del prompt, non di Anthropic):
  rispettata: generico 0 su 3, ciaspolink 3 su 3
La coppia, esecuzione per esecuzione (differiscono solo nel
system prompt):
  esecuzione 1: generico 19 righe, ciaspolink 2 righe: confermata
  esecuzione 2: generico 17 righe, ciaspolink 2 righe: confermata
  esecuzione 3: generico 17 righe, ciaspolink 2 righe: confermata
  confermata 3 su 3
La prima richiesta, in token (cambia solo il system prompt):
  esecuzione 1: generico 669, ciaspolink 719 (+50)
  esecuzione 2: generico 669, ciaspolink 720 (+51)
  esecuzione 3: generico 669, ciaspolink 718 (+49)
```

- **La risposta**, nella registrazione: **19, 17 e 17 righe** con il neutro, **2 righe** ogni volta con il ruolo e la riga in più. La coppia: **«confermata 3 su 3»**
- Il controllo decide solo le tre righe. Come dato, dalle risposte: «Buongiorno Giulia» con il neutro, «Buongiorno signora Campione» con il ruolo, in tutte e tre

Registrazione del corso, 9 novembre 2026, Claude Code 2.1.319, Sonnet, effort low

Il secondo messaggio

M7-D01, seconda parte: la stessa domanda, senza e con la conversazione

- Dalla guida ai messaggi: «The Messages API is stateless, which means that you always send the full conversational history to the API.» In `claude -p` si riprende con `--resume`
- Una prima chiamata riceve una parola in codice. Poi la stessa domanda, «Qual è la parola in codice di questa prova?», in una **chiamata nuova** e, con `--resume`, **nella sessione della prima**:

`memoria-1, a capo per la slide: «[…]» un taglio`

```
memoria-1 (la parola in codice: LARICE-9861)
  la chiamata nuova, senza --resume:
    Non ho nessuna parola in codice: nel contesto […]
  la chiamata nella sessione della prima, con --resume:
    La parola in codice è LARICE-9861.
  senza --resume la risposta non contiene la parola: confermata
  con --resume la risposta contiene la parola: confermata
  prima richiesta: nuova 616 token, ripresa 662 (+46)
```

- Le **due garanzie**, confermate in tutte e tre le prove: 3 su 3. Come dato, la prima richiesta della chiamata ripresa pesa +46, +49 e +49 token sulla nuova: porta anche la conversazione di prima
- Nell'applicazione la conversazione è un **dato del programma**: la conserva lui, e la rimanda a ogni richiesta

Registrazione del corso, 9 novembre 2026, Claude Code 2.1.319, Sonnet, effort low

Le manopole non ci sono più

Il campionamento non si imposta: resta che cosa limitare e che cosa leggere

- `temperature`, `top_p` e `top_k`, i parametri di campionamento, **non sono supportati** sui modelli attuali, Claude 4.7 e successivi, né su qualunque modello a partire dalla versione API `2026-10-21`: con quella versione una richiesta che li invia riceve un errore **400**, anche con il valore predefinito
- Una richiesta che abbassava `temperature` per risposte più consistenti **perde quell'effetto**, e nessun'altra impostazione lo sostituisce
- Il glossario di Anthropic: anche con `temperature` a 0 i risultati non sono del tutto deterministici, e **input identici possono dare output diversi** tra una chiamata e l'altra
- Il comportamento si guida con il **prompt**: la guida alla migrazione di Claude Opus 5.5 chiede di omettere i tre parametri
- Resta da impostare `max_tokens`: il massimo di token da generare, un **tetto**. Il modello può fermarsi prima
- Resta da leggere `stop_reason`: in ogni risposta riuscita dice **perché** Claude ha finito: `end_turn`, `max_tokens`, `stop_sequence`, `tool_use`, `pause_turn`, `refusal` o `model_context_window_exceeded`

Dove va il grosso del prompt

Due pagine di Anthropic che non dicono la stessa cosa

- La guida al customer support: «Claude actually works best with the bulk of its prompt content written inside the first User turn (with the only exception being role prompting).»
- L'articolo sugli agenti per il commercio: «Critical instructions, such as safety and legal rules, brand constraints, and key user facts such as allergies, always go in the system prompt.»
- Non dicono la stessa cosa, e qui non si sceglie per fede: si mostrano tutte e due, con la fonte, e si guarda che cosa si può **misurare**
- Qui facciamo così: un system prompt **in un file**, con `--system-prompt-file`, che sostituisce l'intero prompt predefinito; con un system prompt proprio si ottiene **solo ciò che si scrive**, e si diventa responsabili di sostituire le indicazioni sugli strumenti e di sicurezza che servono ancora