

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

Modulo 7 — Conoscenza, guardrail, valutazione

La conoscenza: RAG

Da dove ripartiamo

Un assistente ha un system prompt e degli strumenti: e le procedure dell'azienda?

- L'assistente di CiaspoLink, il fornitore di connettività inventato del corso, ha un **system prompt**, che dice chi è e che cosa deve fare, e degli **strumenti**, con cui chiede al codice i dati del cliente
- Gli mancano le **procedure**: come si fa un trasloco, quando si rimborsa una fattura. Stanno nei documenti dell'assistenza. Per chatbot e basi di conoscenza, la guida di Anthropic indica il **recupero**: «use retrieval to ground Claude's responses in a fixed information set»
- Se i documenti sono pochi, basta il contesto: «If your knowledge base is smaller than 200,000 tokens (about 500 pages of material), you can just include the entire knowledge base in the prompt»: una regola pratica, con la sua data, settembre 2024
- Se non ci stanno, si recupera. Il **RAG** è «a method that retrieves relevant information from a knowledge base and appends it to the user's prompt»

Da una guida di Anthropic sulla coerenza delle risposte e dall'articolo «Contextual Retrieval» di Anthropic, settembre 2024

M7-D05 Cercare per significato

Demo del docente: due ricerche sugli stessi dodici articoli

- A voce: la ricerca per parola trova «disdetta» dove il testo dice «recesso»?
- **M7-D05**: dodici articoli dell'assistenza di CiaspoLink e tre domande, in due ricerche. La prima domanda usa le parole dell'articolo che risponde; la seconda e la terza dicono la stessa cosa con **altre parole**
- Per cercare per significato serve un modello di *embedding*, come quelli del Modulo 1: il testo diventa un vettore di numeri, testi vicini nel significato danno vettori vicini, e la vicinanza si misura con il coseno. Qui gira un modello **locale**: «Anthropic does not offer its own embedding model.» Per chi cerca un fornitore, dalla pagina sugli embedding: «One embeddings provider with a wide variety of models and capabilities is Voyage AI by MongoDB.»
- Guardate le due **classifiche**, domanda per domanda: chi trova l'articolo giusto quando cambiano le parole? Il comando, dalla cartella `esercitazioni`:

```
m7_assistenti_llm/s6_conoscenza_e_valutazione/m7_6_la_conoscenza/\
M7-D05_cercare_per_significato/_docente/live.sh \
  ~/corso-claude-code/M7-D05
```

M7-D05 Cercare per significato

Demo del docente: due ricerche sugli stessi dodici articoli

La risposta: **no**. Una ricerca per parola trova le parole che le date, e «disdetta» non è «recesso». Serve il **significato**, come nella seconda domanda della registrazione

la domanda	per parole, il primo	per significato, il primo
«Come si cambia la password del Wi-Fi?»	art-03-password-wifi (10)	art-03-password-wifi (0,804)
«Vado ad abitare in un'altra casa: che fine fa il mio abbonamento?»	**nessuno**: nessun articolo contiene le parole cercate	**art-07-cambio-indirizzo** (0,586)
«Mi hanno fatto pagare due volte lo stesso mese»	art-01-fibra-spia-rossa (3), art-08-guasti-di-zona (3): **non rispondono**	**art-06-addebito-ripetuto** (0,548)

Le classifiche del controllo, i primi di ogni colonna: tra parentesi, a sinistra quante volte compaiono le parole della domanda, a destra il coseno

Registrazione del corso, 9 novembre 2026: embeddinggemma:300m in locale con Ollama, sul computer del docente

Il controllo stampa le classifiche e non decide quale ricerca sia migliore: una dimostrazione, con questi dodici articoli, questo modello locale e queste tre domande. Dice lo script: «Non è Claude: Anthropic non ha un modello di embedding suo.»

Il RAG in due corsie

Indicizzare una volta, interrogare a ogni domanda



- **Una volta sola**, e a ogni documento che cambia: i documenti si spezzano in brani, «usually no more than a few hundred tokens», e ogni brano diventa un vettore. È un **indice**, come quelli di un database: nessun addestramento
- **A ogni domanda**: la domanda diventa un vettore, si cercano i brani più vicini, si aggiungono al prompt, e la risposta cita il brano da cui viene
- La definizione è nell'articolo «Contextual Retrieval»: «RAG is a method that retrieves relevant information from a knowledge base and appends it to the user's prompt»

Contextual Retrieval, in numeri

Ricerca per parola e per significato insieme, con il contesto: le cifre di Anthropic

- Due ricerche, che si combinano. **BM25**: «a ranking function that uses lexical matching to find precise word or phrase matches»; l'**embedding** cerca il significato
- **Contextual Retrieval**: a ogni brano si antepone un contesto che lo spiega, «prepending chunk-specific explanatory context to each chunk before embedding ("Contextual Embeddings") and creating the BM25 index ("Contextual BM25")»

i recuperi falliti, nei primi 20 brani	tasso di fallimento
il punto di partenza dell'articolo	**5,7 %**
con Contextual Embeddings e Contextual BM25	**2,9 %**, cioè −49 %
in più, il *reranking* dei brani	**1,9 %**, cioè −67 %

Le cifre sono di Anthropic, dall'articolo «Contextual Retrieval», settembre 2024: valgono per le prove di quell'articolo

M7-D06 Tre brani, una risposta con la fonte

Demo del docente in Claude Code: due domande, due versioni, una frase di differenza

- La frase alla prova, da «Reduce hallucinations»: «Allow Claude to say “I don’t know”: Explicitly give Claude permission to admit uncertainty. This technique **can** drastically reduce false information.» Sulla fonte: «Make Claude’s response auditable by having it cite quotes and sources for each of its claims.»
- L’assistente di CiaspoLink cerca in **tre brani** delle procedure con uno strumento, `cerca_kb`, e risponde; uno *structured output* (nelle righe del controllo, l’uscita strutturata) dice se la risposta è coperta e da quale procedura viene
- Due domande: una che un brano **copre**, «Il mio router in comodato si è guastato: tra quanto arriva quello nuovo?», e una che **nessuno** copre, «Se mi cade il router e si rompe, quanto devo pagare per averne uno nuovo?»
- Due versioni del system prompt, che differiscono in **una frase**: «Se non sei sicuro o se i brani non contengono le informazioni necessarie, scrivi al cliente che non lo sai.» Sul modello dell’esempio della guida: «If you’re unsure about any aspect or if the report lacks necessary information, say “I don’t have enough information to confidently assess this.”»
- Guardate il **codice** della procedura nel campo strutturato e che cosa risponde quando i brani non bastano. Il comando, dalla cartella `esercitazioni`:

```
m7_assistenti_llm/s6_conoscenza_e_valutazione/m7_6_la_conoscenza/\
M7-D06_tre_brani/demo/in_classe.sh ~/corso-claude-code/M7-D06
```

M7-D06 Tre brani, una risposta con la fonte

Demo del docente in Claude Code: due domande, due versioni, una frase di differenza

```
il controllo, a capo per la slide

La domanda coperta: il codice giusto, KB-90, nell'uscita
strutturata (un dato):
  con il permesso di dire «non lo so»: 3 su 3
  senza quel permesso: 3 su 3
La domanda non coperta: coperta false, cioè «i brani non
contengono la risposta» (n su 3):
  con il permesso di dire «non lo so»: 3 su 3; (dato) con un
  numero che non sta nei brani: 0 su 3
  senza quel permesso: 3 su 3; (dato) con un numero che non sta
  nei brani: 0 su 3
«Allow Claude to say "I don't know": Explicitly give Claude
permission to admit uncertainty.»:
  non distinguibile (3 contro 3: la stessa cosa con e senza il
  permesso)
```

- Il **codice** giusto, KB-90: 3 su 3 con il permesso e 3 su 3 senza. Sulla domanda non coperta le risposte dicono che le procedure non trattano il caso: nessun numero fuori dai brani, in nessuna delle dodici chiamate
- Su questa domanda il permesso non ha cambiato il campo. Anthropic scrive «can», e nella stessa pagina: «they don’t eliminate them entirely. Always validate critical information»

Registrazione del corso, 9 novembre 2026, Claude Code 2.1.319, Sonnet, effort low, tre esecuzioni per variante

RAG o strumento?

Una fotografia indicizzata, o il dato vivo

	Recupero (RAG)	Strumento
Su che cosa	una **fotografia indicizzata** dei documenti: procedure, listini, orari	**dati vivi e azioni**: lo stato di una linea, una fattura, una segnalazione
Che cosa dice	«avendo letto alcuni documenti, ti spiego»	«chiedo al sistema, e ti dico»
Che cosa fa	recupera i brani, che ancorano la risposta a un insieme fisso di informazioni	chiede al **vostro codice** di eseguire, e aspetta: il modello non esegue nulla da solo

> Dalla guida al customer support: «When dealing with queries that require real-time information, such as account balances or policy details, embedding-based RAG approaches are not sufficient.»

A che cosa servono gli strumenti, dalla pagina sul tool use: «Actions with side effects.» «Fresh or external data.» «Calling into existing systems.»

I documenti si cercano, i dati vivi si chiedono a uno strumento.

Quale schema per quale problema

Dalla chat all’agente: si legge dall’alto

Schema	Quando	Che cosa comporta
Chat semplice	un compito generale su un testo che date voi: riassumere, tradurre, riscrivere	niente da costruire
Prompt + contesto	pochi documenti, un caso alla volta	i documenti nel prompt, a ogni chiamata
RAG	molti documenti, domande su di essi, risposte con la fonte	un indice, gli embedding, e tenerli aggiornati
Strumento	dati vivi e azioni: la linea, la fattura, la segnalazione	schemi, esecuzione, permessi
Agente	compiti aperti a più passi, con una persona che controlla	guardrail, limiti, supervisione

Si legge dall’alto: il primo schema che risolve il problema **è quello giusto**. Anthropic raccomanda «finding the simplest solution possible, and only increasing complexity when needed»

Da «Building effective agents», Anthropic

Quale schema per quale problema

Dalla chat all’agente: si legge dall’alto

1. «Che cosa dicono le procedure sul trasloco della linea?» **RAG**: molti documenti, domande in linguaggio naturale, la risposta con la fonte
2. «A che punto è il guasto di questa linea?» **Strumento**: il dato vive nei sistemi e cambia di ora in ora, e nessun indice sarebbe aggiornato
3. La bozza di risposta a un reclamo, con la lettera da firmare. **Prompt + contesto**: un documento alla volta e una persona che firma; lo schema più semplice basta
4. Seguire una linea instabile, controllare i guasti della zona, avvisare i clienti. **Agente**, con una persona che controlla, oppure un **flusso**: se i passi sono sempre gli stessi, un programma li fa meglio

Quattro casi costruiti per il corso, sull’assistenza di CiaspoLink

M7-D10 L’assistente in un progetto di claude.ai

Demo del docente in claude.ai, dal vivo; la potete rifare sul vostro account, se volete

- La frase **sotto prova**, da «How can I create and manage projects?»: «Anything you upload to this space will be used across all of your chats within that project.» Su claude.ai si guarda **a occhio**
- Due **chat nuove**, con la stessa domanda di un cliente: la prima **fuori** dai progetti, senza allegati; la seconda **in un progetto** con quattro procedure di CiaspoLink nella conoscenza e le istruzioni. È lo **stesso assistente**, senza il banco di prova: niente server MCP, niente `claude -p`

`domanda.txt, la stessa nelle due chat, a capo per la slide`

```
A quale numero devo chiamare per l'Assistenza Prioritaria di
CiaspoLink?
```

- I file, `domanda.txt`, `istruzioni-progetto.txt` e `conoscenza/`: in `m7_assistenti_llm/s6_conoscenza_e_valutazione/m7_6_la_conoscenza/M7-D10_progetto_claude_ai/demo/`; dopo `tools/prepara_esercizio.sh M7-D10`, in `~/corso-claude-code/M7-D10`
- In tutte e due, «Memory» spenta dal menu «+» **prima** del primo messaggio: «Once the chat starts, the setting can’t be changed.» Una chat così «doesn’t search your past chats from it, and doesn’t save anything from it to memory»; in un progetto «doesn’t use or add to the project’s memory»

M7-D10 L’assistente in un progetto di claude.ai

Demo del docente in claude.ai, dal vivo; la potete rifare sul vostro account, se volete

istruzioni-progetto.txt, a capo per la slide, 1 di 2

```
<role>
Sei l'assistente virtuale dell'assistenza clienti di CiaspoLink,
un operatore di connettività, e rispondi ai clienti che scrivono
in chat.
</role>

<context>
Le procedure di CiaspoLink sono i file kb-NN nella conoscenza di
questo progetto. Il cliente si regola su quello che gli rispondi.
</context>

<instructions>
1. Trova nella conoscenza del progetto la procedura che riguarda
la domanda del cliente.
2. Rispondi con ciò che dice la procedura e scrivi il suo codice,
nella forma KB-NN.
3. Prima di rispondere, controlla che il codice sia quello del
file da cui prendi la risposta.
</instructions>
```

M7-D10 L’assistente in un progetto di claude.ai

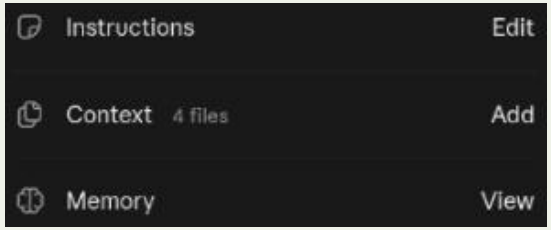
Demo del docente in claude.ai, dal vivo; la potete rifare sul vostro account, se volete

istruzioni-progetto.txt, a capo per la slide, 2 di 2

```
<format>
Al massimo quattro frasi, in italiano, dando del lei al cliente.
</format>

<constraints>
Se la conoscenza del progetto non contiene la risposta, scrivi che
non lo sai.
</constraints>
```

Prova del corso, l'assistente di CiaspoLink



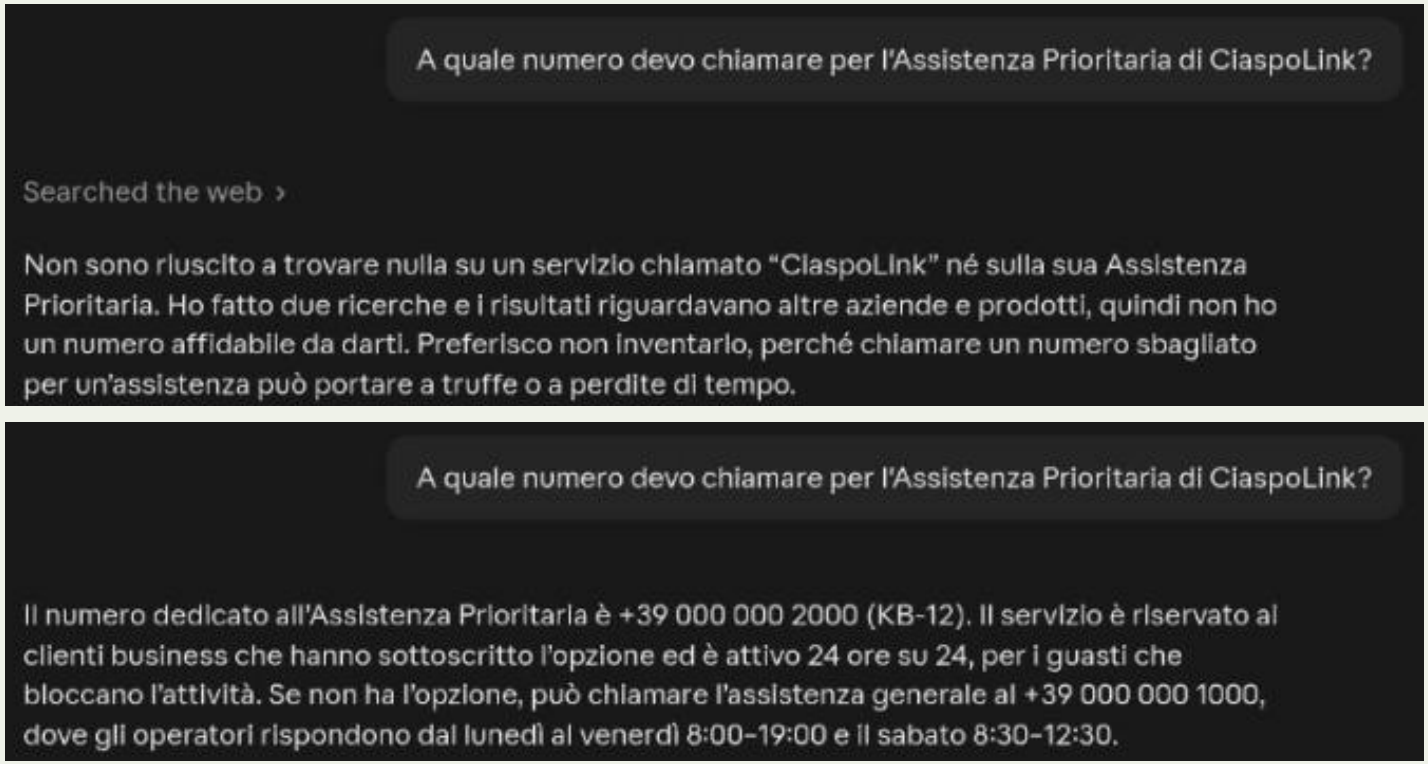
La pagina del progetto, in due ritagli: il titolo e, a destra, «Instructions», «Context» con quattro file, «Memory»
Registrazione del corso, 9 novembre 2026: claude.ai, Sonnet; schermata del docente

- Il **progetto**: le quattro procedure nella conoscenza e le **istruzioni**: «you can define project instructions for each project to further tailor Claude’s responses»
- Guardate: senza le procedure che cosa risponde? Nel progetto ci sono il numero e il codice **KB-12**? CiaspoLink l’ha inventato il corso: codice e numero non stanno altrove

M7-D10 L’assistente in un progetto di claude.ai

Demo del docente in claude.ai, dal vivo; la potete rifare sul vostro account, se volete

La registrazione del corso: la stessa domanda, due chat



Sopra la chat fuori dai progetti, con la domanda; sotto la chat nel progetto, con le procedure: la domanda e la risposta

Registrazione del corso, 9 novembre 2026: claude.ai, Sonnet, memoria spenta; schermate del docente

- **Fuori dai progetti**: ha cercato sul web, non ha trovato niente su CiaspoLink e non ha dato un numero
- **Nel progetto**: «+39 000 000 2000 (KB-12)», il numero e il codice, senza una ricerca sopra la risposta

M7-D10 L’assistente in un progetto di claude.ai

Demo del docente in claude.ai, dal vivo; la potete rifare sul vostro account, se volete

- Il **controllo** dell’elemento legge le due risposte salvate: «Dimostrazione: il controllo legge le due risposte come le avete salvate; che cosa ha fatto claude.ai si guarda sullo schermo.»

la risposta	il codice KB-12	il numero	i codici citati
la chat, senza progetto	**no**	**no**	nessuno
la chat nel progetto con le procedure	sì	sì	KB-12, fra le procedure caricate: sì

Le righe (dato) del controllo, in tabella. L’ultima: «il codice e il numero insieme: la chat, senza progetto: no; la chat nel progetto con le procedure: sì»

Registrazione del corso, 9 novembre 2026: le due risposte salvate da claude.ai, `tools/verifica.sh M7-D10`

- Quando la conoscenza cresce: «When your project knowledge approaches the context window limit, Claude will automatically enable RAG mode to expand your project’s capacity by up to 10x», e usa «a project knowledge search tool». Le nostre quattro procedure sono poche pagine
- Un progetto è lo **stesso assistente** senza il banco di prova: le istruzioni e la conoscenza stanno nel progetto, e ciò che si carica vale per tutte le sue chat