

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

Modulo 7 — Conoscenza, guardrail, valutazione

Valutare un assistente

Come si fa a sapere se aiuta?

Criteri specifici e misurabili, e molti casi

- Il banco di prova è l'assistente simulato delle esercitazioni: quello di CiaspoLink, il fornitore di connettività inventato del corso, provato su situazioni note
- A voce: come decidereste se il vostro assistente è migliorato?
- La documentazione di Anthropic: un criterio di successo è **specifico** (dice che cosa si vuole ottenere) e **misurabile** (numeri, o scale qualitative ben definite)
- Criteri tipici di quell'elenco: fedeltà al compito, coerenza, tono e stile, tutela della privacy, uso del contesto, latenza, prezzo
- **Più casi** con una valutazione automatica un po' meno fine valgono più di pochi casi valutati a mano benissimo

Le parole delle valutazioni

Le definizioni di Anthropic, e che cosa sono sul nostro banco di prova

Parola	Che cos'è	Sul banco di prova
eval	un test per un sistema di AI: un input e una logica di grading sul suo output	una serie di casi (un *eval set* offline)
task	un singolo test, con input e criteri di successo	un caso, con le sue asserzioni
trial	ogni tentativo di svolgere il task; va isolato, da un ambiente pulito	una chiamata di `claude -p`
grader	la logica che assegna un punteggio a un aspetto del comportamento	le asserzioni, poi il giudice
transcript	la registrazione completa di un trial: output, chiamate agli strumenti, ragionamento	`trascrizione.md` e `registro.jsonl`
outcome	lo stato finale dell'ambiente alla fine del trial	ciò che il server ha davvero fatto

✈ L'esempio di Anthropic: un agente può dire «il volo è prenotato»; l'*outcome* è se la prenotazione esiste davvero.

Scoprire con il cliente simulato, misurare con gli snapshot

Due articoli di Anthropic tirano in direzioni diverse

- L'articolo sugli agenti per il commercio: una valutazione con cliente simulato è «*a poor tool for measurement*», utile però per **trovare i casi**: «*use them to discover cases, then write each case as a snapshot*»
- L'articolo sulle valutazioni: per gli agenti conversazionali «*they often require a second LLM to simulate the user*»
- Uno **snapshot**: si costruisce lo stato della conversazione e si aggiunge il messaggio del cliente, una sola chiamata e tanti controlli
- Che cosa facciamo: il **cliente simulato per scoprire** (M7-E01), gli **snapshot per misurare** (M7-E02, M7-E03)

Prima il codice, poi il giudice

Dove si può decide il codice; il giudice si prova prima di fidarsene

- </> Anthropic: grader **deterministici dove possibile**, un giudice LLM dove serve, le persone con parsimonia
- Di solito è meglio valutare **che cosa l'agente ha prodotto**, non il percorso che ha seguito
- Il giudice si prova una volta **sui casi che anche il codice sa valutare**, per vedere se i due concordano
- Si calibra da vicino con chi conosce il lavoro
- ? Gli si dà una **via d'uscita**: «*Unknown*» quando non ha informazioni sufficienti; il valore più importante dello schema
- Punti di forza, debolezze e motivazione **accanto al voto**: senza, i modelli tendono ai voti intermedi

Si valuta l'esito, con casi veri, e prima di fidarsi del giudice lo si calibra.

Regressione e casi negativi

Una valutazione vale quanto i casi negativi che contiene

- La **regressione**: l'agente gestisce ancora tutti i task di prima? Il tasso di successo deve stare vicino al 100 per cento
- Si prova sia il caso in cui un comportamento deve verificarsi sia quello in cui **non deve**: «*One-sided evals create one-sided optimization*»
- L'articolo sugli agenti per il commercio: per ogni «dovrebbe rifiutare», un «dovrebbe servire»; per ogni «dovrebbe chiedere», un «fai e basta»
- **pass^k**: la probabilità che **tutti** i k trial riescano; conta soprattutto per chi parla con i clienti. Con il 75 per cento a trial e 3 trial: $0{,}75^3 \approx 42$ per cento