

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

Modulo 8 — Costi, piano Pro e ottimizzazione

Dove siamo e che cosa serve

Dove siamo e che cosa serve

Modulo 8 di 9: Costi, piano Pro e ottimizzazione

- **Dal Modulo 1:** il **token** è l'unità con cui si conta e si paga, e la finestra di contesto è la memoria di un turno; una stessa frase pesa 27 token in italiano e 17 in inglese
- **Dal Modulo 2:** `claude -p --output-format json` restituisce un JSON, e in quel JSON c'è `usage`; l'effort regola quanto lavoro fa Claude, e quel lavoro si paga in token
- **Dal Modulo 4:** il **ciclo degli strumenti**: ogni uso di uno strumento è un'altra richiesta, con tutta la conversazione; un subagent fa richieste sue
- **Dal Modulo 6:** il contesto è un bilancio: più contesto Claude elabora, più token consuma, a ogni turno
- **Dal Modulo 7:** un assistente non ha memoria: a ogni turno si rimandano la conversazione e le definizioni degli strumenti

Il costo è una misura, non un'impressione: si calcola prima, si legge dopo.

Il gioco del prezzo

A voce, senza calcolatrice

Indovinate, a voce: mille risposte a mille email di una pagina, con Opus, il modello più capace compreso nel Pro, a listino API. A naso, quanto costano in tutto?

A circa 50 centesimi	**B** circa 5 dollari	**C** circa 50 dollari	**D** circa 500 dollari

L'indizio, per ragionare: una pagina in italiano, **circa 1.000 token** (un'ipotesi, per l'ordine di grandezza); una risposta breve, circa 150; i listini sono in dollari per milione di token

La più vicina è la **B**: con Opus 5.5 circa 7 dollari, meno di 20 centesimi con Haiku 5.5 (listino del 10 novembre 2026). Il conto lo rifacciamo in «Il conto in token», riga per riga, con il listino sotto gli occhi

Il filo del modulo

Quanto costa una risposta, chi la paga, come si fa pagare meno

- **Sul piano Pro:** che cosa c'è dentro, i due limiti, dove si guarda
- **Il conto:** token in entrata e in uscita, il campo `usage`, il modello giusto per il lavoro
- **Due sconti:** la cache del prompt, per ciò che si ripete; il Batch, per ciò che può aspettare
- **Pro o API:** quando si passa all'API, e come si tiene d'occhio la spesa
- **Ridurre i token,** e il laboratorio: un prompt d'esempio, lungo e ripetitivo, misurato e tagliato, a parità di qualità
- **Che cosa resta in mano:** l'albero di decisione e il cheat sheet dei costi in `riferimenti/`, e un conto che sapete rifare