

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

Modulo 8 — Costi, piano Pro e ottimizzazione

Il conto in token

Si paga ciò che si legge e ciò che si scrive

Il listino API per milione di token, letto il 10 novembre 2026

Ogni risposta di Claude ha un conto: i **token** che il modello legge, in entrata, e quelli che scrive, in uscita, ciascuno a un prezzo diverso per ogni modello

	in entrata (ciò che legge)	in uscita (ciò che scrive)
Claude Haiku 5.5	0,10 $	0,50 $
Claude Sonnet 5.5	2 $	10 $
Claude Opus 5.5	4 $	20 $
Claude Fable 5.2	8 $	40 $

- Dal più economico al più capace, in quest'ordine
- Haiku 5.5 ha questi prezzi fino a 100.000 token di prompt; oltre, 0,50 $ e 2,50 $
- I token non si stimano dal testo: si leggono da `usage`, nella risposta
- È il listino dell'API: sul Pro non si paga a token, ma i token restano la misura del lavoro

Il tovagliolo

Il conto a mano: mille email, mille risposte

Mille email di una pagina (circa 1.000 token l'una, un'ipotesi), mille risposte brevi (circa 150 token l'una): 1.000.000 di token in entrata, 150.000 in uscita

	entrata	uscita	totale
Haiku 5.5	0,10 $	0,075 $	0,175 $
Sonnet 5.5	2 $	1,50 $	3,50 $
Opus 5.5	4 $	3 $	**7 $**
Fable 5.2	8 $	6 $	14 $

Con Opus, il modello più capace compreso nel Pro, mille risposte a mille email costano circa 7 dollari, a questo listino

Lo stesso lavoro, a parità di token: Opus costa 40 volte Haiku, Fable 80 volte

L’uscita pesa cinque volte

Perché le risposte corte fanno risparmiare

- Su tutti i modelli di questo listino un token in uscita costa **cinque volte** un token in entrata
- Il modello genera un token alla volta: per Anthropic è da qui che viene gran parte dell’attesa e del costo dell’output
- «Ask for the answer you will read, not the one that looks thorough»: chiedete la risposta che leggerete davvero
- Nelle misure di Anthropic, risposte più brevi: circa il 13 % di costo in meno, con il 39 % di token in uscita in meno (e avverte: i numeri cambiano con modelli e prezzi)
- Anche il ragionamento e le chiamate agli strumenti sono output, alla stessa tariffa, anche quando il testo del ragionamento non viene restituito

Leggere il conto

Il JSON di una chiamata vera: dove stanno i token e il costo

la risposta di claude -p in JSON, dalla registrazione (Haiku, 10 novembre 2026)

```
{
  "stop_reason": "end_turn",
  "total_cost_usd": 0.00115993,
  "usage": {
    "input_tokens": 2,
    "cache_creation_input_tokens": 767,
    "cache_read_input_tokens": 3133,
    "output_tokens": 1950, […]
  }, […]
  "result": "Buongiorno Marta. Dal solo sintomo non […]", […]
}
```

- In entrata la somma di tre campi: 2 + 767 + 3.133 = **3.902**. Con la cache attiva `input_tokens`, da solo, conta soltanto ciò che viene dopo l'ultimo punto di cache, il *breakpoint* (la cache: «La cache del prompt»)
- `total_cost_usd` è calcolato sui conteggi a prezzo di listino: una stima lato client, che può differire dalla fattura

M8-D01 Quanti token pesa una frase?

Demo del docente sull’API: il conteggio prima di spedire

- La frase alla prova, dalla documentazione dell’API: l’endpoint «can be used to count the number of tokens in a Message, including tools, images, and documents, without creating it»
- La fa il docente, con la sua chiave: il Pro non include l’API. Si guarda la stessa richiesta di un cliente, in italiano e in inglese

`testi/frase-it.txt` e `testi/frase-en.txt`, a capo per la slide

```
La connessione cade ogni sera verso le nove: potete controllare
la linea?

The connection drops every evening around nine: can you check
the line?
```

```
m8_costi_ottimizzazione/s6_costi_e_ottimizzazione/\
m8_3_il_conto_in_token/M8-D01_quanti_token/\
demo/chiama.sh ~/corso-claude-code/M8-D01
```

- Si guarda il conteggio di ogni testo, e che la risposta non sia un messaggio. La chiave arriva a `curl` sullo STDIN, mai sulla riga di comando

M8-D01 Quanti token pesa una frase?

Demo del docente sull’API: il conteggio prima di spedire

```
dalla registrazione del corso, 10 novembre 2026, a capo per
la slide

file      caratteri  input_tokens
frase-it         73            34
frase-en         71            26
(dato) modello della richiesta: claude-haiku-5-5
La stessa frase in due lingue: italiano 34 token su 73
caratteri, inglese 26 su 71: +8 token. Una misura, nessun
verdetto.
La garanzia: nessuna risposta porta id, content, stop_reason o
usage: contare non ha creato un messaggio: confermata.
```

- Il conteggio è una **stima**: il numero effettivo di token di un messaggio creato può differire di poco
- È gratuito, con limiti di richieste al minuto, e non usa la cache
- Nel Modulo 1 lo stesso effetto su un’altra frase: 27 token contro 17. Il tokenizer che Anthropic ha pubblicato vale solo per i modelli più vecchi: il numero si chiede all’API, o si legge da `usage`

M8-D02 Il conto dal campo usage

Demo del docente in Claude Code: la stessa domanda, due formati

- La frase alla prova, dalla guida ai costi: «Ask for the answer you will read, not the one that looks thorough.»
- La stessa domanda, tre esecuzioni per braccio; cambia soltanto la richiesta sul formato:

domanda.txt, a capo per la slide

```
Perché la connessione in fibra di un cliente cade ogni sera verso
le nove e torna da sola dopo pochi minuti? Di giorno non succede,
il router resta acceso e gli altri clienti della zona non
segnalano nulla.
```

formato-breve.txt e formato-lungo.txt, a capo per la slide

```
Rispondi in una riga sola: la causa più probabile e il primo
controllo da fare.

Rispondi con una relazione in sei sezioni, ciascuna con il suo
titolo: sintomo, cause possibili, controlli da fare, strumenti,
quando aprire un guasto, come evitarlo in futuro.
```

M8-D02 Il conto dal campo usage

Demo del docente in Claude Code: la stessa domanda, due formati

Indovinate, a voce: stessa domanda, una riga o sei sezioni. Quante volte costa di più la seconda?

Ogni chiamata è una sessione nuova di `claude -p`, su Haiku con effort low, senza strumenti:

```
m8_costi_ottimizzazione/s6_costi_e_ottimizzazione/\
m8_3_il_conto_in_token/M8-D02_il_conto_dal_campo_usage/\
demo/in_classe.sh ~/corso-claude-code/M8-D02
```

Il controllo legge ogni JSON: token in entrata, token in uscita, `total_cost_usd` e il costo ricalcolato, ciascun conteggio al suo prezzo

M8-D02 Il conto dal campo usage

Demo del docente in Claude Code: la stessa domanda, due formati

	token in uscita, breve → lunga	costo ricalcolato, breve → lunga	
esecuzione 1	218 → 2.662 (×12,2)	0,000248 $ → 0,001479 $ (×6,0)	confermata
esecuzione 2	224 → 2.464 (×11,0)	0,000119 $ → 0,001240 $ (×10,4)	confermata
esecuzione 3	165 → 2.455 (×14,9)	0,000090 $ → 0,001235 $ (×13,8)	confermata

- Nella registrazione del 10 novembre 2026 la risposta lunga ha più token in uscita e un costo più alto: **confermata 3 su 3**
- Fra `total_cost_usd` e il costo ricalcolato la differenza più grande è 0,000000 $: una dimostrazione della formula, non una garanzia sulla fattura
- Sul piano quella cifra in dollari è un'indicazione del lavoro fatto, non una fattura; e la documentazione chiede di non fatturare da questi campi

Si pagano i token letti e scritti: il conto si fa prima e si rilegge dopo, riga per riga.