

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

Modulo 8 — Costi, piano Pro e ottimizzazione

Il modello giusto per il lavoro

Quale modello per quale lavoro

Tre pagine di Anthropic, ciascuna con la sua frase

- Claude ha più modelli, dal più economico al più capace: Haiku, Sonnet, Opus e Fable. Per ogni lavoro se ne sceglie uno, e le pagine di Anthropic dicono cose diverse
- **La pagina dei prezzi:** «Choose Haiku for simple tasks, Sonnet for most production workloads, and Opus for the most complex reasoning»
- **La guida alla scelta del modello:** «Most workloads start with Claude Opus 5.5»
- **La guida ai costi:** per il lavoro ad alto volume con output che si possono controllare, «Try Claude Haiku 5.5 first». Un post di Anthropic aggiunge: Haiku per classificazione, routing ed estrazione, i modelli piccoli dove un errore è facile da notare
- Un esempio del corso, il *routing dei modelli*: Haiku per il pre-processing economico, Sonnet per la parte difficile, Opus per la rara parte difficilissima

Tre pagine, tre risposte: non c'è un modello migliore, c'è una scelta, con una misura accanto.

Quattro criteri, con la misura accanto

Si confronta il costo del lavoro finito, non del token

Criterio	Come si misura
Costo	il costo per task completato, non per token: i token di un task fallito si pagano comunque
Latenza	quanto aspetta chi aspetta, con il vostro prompt
Qualità	sui vostri casi, con le etichette attese, o con un modello che fa da giudice (Moduli 2 e 7)
Privacy	quali dati escono e a quali condizioni: lo vediamo in «Pro o API?»

Il modello giusto è il più economico di cui spedireste il risultato.

Latenza: chi aspetta?

E l'effort: la manopola prima del modello

	Fable 5.2	Opus 5.5	Sonnet 5.5	Haiku 5.5
Latenza comparativa	Moderate	Moderate	Fast	**Fastest**

- Una persona davanti allo schermo: la latenza pesa, e un modello piccolo può bastare
- Un lavoro notturno: la latenza non pesa (lo vediamo in «Batch»)
- Un post di Anthropic: «Before you move models, try adjusting your effort level»: l'effort è un controllo più fine per costo e capacità, e riguarda tutti i token della risposta
- `low` è il più efficiente: forte risparmio di token e qualche riduzione di capacità, per i compiti semplici

M8-D04 Il modello giusto per il lavoro

Demo del docente in Claude Code: otto ticket, tre modelli

- La frase alla prova, dalla guida ai costi: per «High-volume work with outputs you can check», «Try Claude Haiku 5.5 first»
- **Indovinate, a voce**: su otto ticket da classificare, Haiku ne sbaglia più di Opus?
- Otto ticket inventati con l'etichetta attesa, due con parole che portano altrove: «Vi pago il canone ogni mese […] da lunedì la linea di casa è morta» è un guasto, non una fattura. Una chiamata, tre esecuzioni per modello; al posto di @@TICKET@@ gli otto ticket:

demo/prompt.txt, a capo per la slide

```
Classifica ciascuno dei ticket numerati qui sotto in una sola
categoria fra guasto, lentezza, fattura, attivazione, secondo il
problema che il cliente chiede di risolvere. Scrivi le etichette
nell'ordine dei ticket, una per ticket.

@@TICKET@@
```

```
m8_costi_ottimizzazione/s6_costi_e_ottimizzazione/\
m8_4_il_modello_giusto/M8-D04_il_modello_giusto/\
demo/in_classe.sh ~/corso-claude-code/M8-D04
```

- Si guardano le etichette giuste e il costo per ticket giusto, modello per modello

M8-D04 Il modello giusto per il lavoro

Demo del docente in Claude Code: otto ticket, tre modelli

	etichette giuste	costo per chiamata	per ticket giusto	ms API
Haiku	24 su 24	0,000242 $	**0,000030 $**	2.077
Sonnet	24 su 24	0,002586 $	0,000323 $	1.399
Opus	24 su 24	0,004682 $	0,000585 $	1.078

- Nella registrazione del 10 novembre 2026, tre esecuzioni per modello, valori medi, con gran parte del prompt già in cache: «Il costo per ticket giusto di Haiku è il più basso: confermata 3 su 3.»
- L'accuratezza qui è solo un dato: 8 giuste su 8 per ogni modello, in ogni esecuzione. Su otto ticket non si conclude: sui vostri casi si misura
- Sul tempo la prova non decide: `duration_api_ms` è solo un dato, e l'output di Haiku qui è più lungo, da 275 a 367 token contro i 90–165 di Sonnet e i 90–97 di Opus
- La guida ai costi: «Compare models on cost per completed task, not per token, because you pay for completed tasks.»