

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

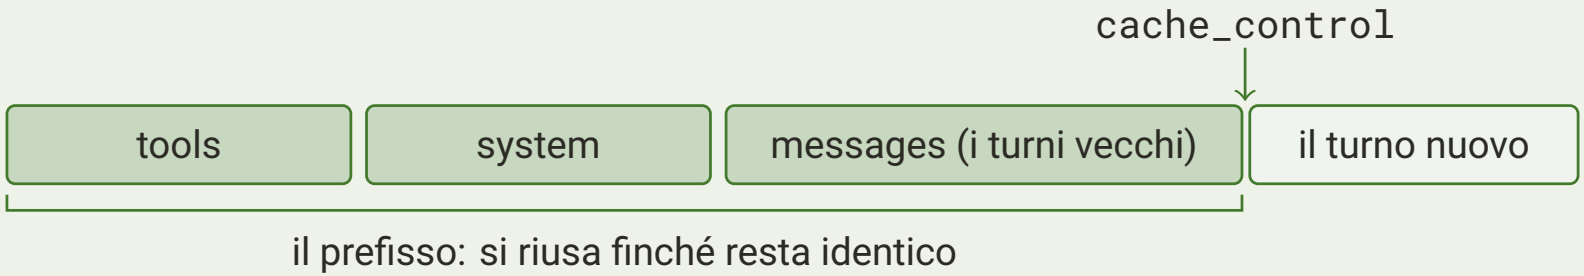
Modulo 8 — Costi, piano Pro e ottimizzazione

La cache del prompt

Il prefisso che si ripete

Tutto viene rimandato a ogni turno: la parte uguale si può riusare

- Claude Code, come ogni assistente, rimanda tutta la conversazione a ogni richiesta: un task di 40 turni invia 40 volte il suo primo turno



Schema illustrativo: l'ordine del prefisso, tools, system, messages

- Se il prefisso è in cache si riusa; altrimenti si elabora tutto e il prefisso va in cache quando inizia la risposta
- Sull'API si attiva con un campo `cache_control` al primo livello del JSON, o con punti di cache, i *breakpoint*, sui blocchi, fino a 4; in Claude Code è automatica

Quanto costa, quanto fa risparmiare

Si paga di più la scrittura, molto di meno la lettura

	rispetto al prezzo in entrata
Scrittura in cache, durata 5 minuti	1,25 volte
Scrittura in cache, durata 1 ora	2 volte
Lettura dalla cache	0,1 volte (0,05 su Opus 5.5 e Sonnet 5.5; 0,025 su Fable 5.2)

- Con la durata a 5 minuti la scrittura si ripaga con una lettura; a 1 ora, con due
- Su un abbonamento, entro il piano, la conversazione principale e le esecuzioni `-p` usano la cache da un'ora
- Nelle misure di Anthropic la cache ha ridotto il costo di un fattore da 4,8 a 7,2 su un agente di ricerca, dall'83 all'86 % su un piccolo agente di smistamento. Sono risultati interni e indicativi, non garanzie
- La guida ai costi: «Turn on prompt caching before any other lever»

Quando non si applica

Sotto la soglia, o quando il prefisso cambia

- **Sotto la soglia:** sotto i 512 token, sui modelli attuali, niente cache e nessun errore: lo si vede da `usage`, con scrittura e lettura entrambe a zero
- **Il prefisso che cambia:** una modifica in qualunque punto invalida tutto ciò che segue, nell'ordine tools, system, messages
- **Il breakpoint sbagliato:** sul blocco che cambia a ogni richiesta si paga una scrittura ogni volta, senza mai una lettura
- **Un cache miss:** fa pagare l'intero prefisso al prezzo di scrittura, non di lettura

Il prefisso che si ripete costa molto meno: ma solo se non cambia.

M8-D03 La cache, vista nel contatore

Demo del docente in Claude Code: cinque chiamate, lo stesso prefisso

- La frase alla prova, dalla documentazione di Claude Code: «Claude Code manages prompt caching automatically.»
- **Indovinate, a voce**: cambio modello a metà conversazione: la cache vale ancora?
- Un prefisso di circa 2.600 token, due procedure del progetto del corso. Cinque chiamate in fila: la prima, la stessa ripetuta, con `DISABLE_PROMPT_CACHING=1`, su Sonnet, di nuovo su Haiku; tre serie. Si guardano i token scritti, letti e in `input_tokens`

demo/domanda.txt, a capo per la slide

```
Una cliente dice che il telefono di casa è muto ma internet
funziona: qual è il primo controllo da farle fare? Rispondi in una
riga.
```

```
m8_costi_ottimizzazione/s6_costi_e_ottimizzazione/\
m8_5_la_cache/M8-D03_la_cache_nel_contatore/\
demo/in_classe.sh ~/corso-claude-code/M8-D03
```

M8-D03 La cache, vista nel contatore

Demo del docente in Claude Code: cinque chiamate, lo stesso prefisso

chiamata	modello	input	scritti	letti	totale
la prima	Haiku	2	2.612	0	2.614
la stessa, ripetuta	Haiku	2	0	2.612	2.614
con la cache disattivata	Haiku	2.614	0	0	2.614
su un altro modello	Sonnet	2	2.591	0	2.593
di nuovo su Haiku	Haiku	2	0	2.612	2.614

- La serie 1 della registrazione del 10 novembre 2026. Le cinque righe sono le garanzie che il controllo decide, in ognuna delle tre serie: **confermate, 15 su 15**
- La risposta, dalla stessa pagina: «Each model has its own cache.» Su Sonnet letti 0, e ne scrive una sua; tornando su Haiku si legge di nuovo
- Un dato, non una garanzia: tutti i token scritti sono nella cache da un’ora. Le chiamate sono a pochi secondi l’una dall’altra: la durata della cache non è messa alla prova