

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

Modulo 8 — Costi, piano Pro e ottimizzazione

Batch: metà prezzo, se si può aspettare

Batch: metà prezzo, se si può aspettare

Sull’API, non sul piano: lo sconto, in cambio dell’attesa

- Non tutto il lavoro ha qualcuno davanti allo schermo
- **Lo sconto:** la Batch API fa pagare ogni token la metà, in entrata e in uscita, anche quelli in cache
- **L’attesa:** la maggior parte dei batch si completa entro un’ora; un batch che non finisce entro 24 ore scade
- **Il volume:** fino a 100.000 richieste o 256 MB per batch; i risultati in un file `.jsonl`, una riga per richiesta, disponibili per 29 giorni
- **Si somma alla cache del prompt**, la parte ripetuta di un prompt riletta a prezzo ridotto: i due sconti si combinano, ma in Batch il riuso della cache è *best-effort*, non garantito
- A voce: che cosa, nel vostro lavoro, può aspettare fino a domattina?
- Per esempio: i ticket da classificare la sera, un report di fine giornata, una valutazione su mille casi. Non il cliente che aspetta in chat

Ciò che può aspettare costa la metà.

Diecimila ticket al mese

Il conto a listino, con le ipotesi scritte

- **Le ipotesi:** ogni ticket è una pagina in entrata (circa 1.000 token) e una risposta breve in uscita (150 token); nessuna cache
- **Il listino** del 10 novembre 2026, per milione di token, entrata e uscita: Haiku 5.5 0,10 $ e 0,50 $ (prompt fino a 100.000 token), Sonnet 5.5 2 $ e 10 $, Opus 5.5 4 $ e 20 $

	un ticket	10.000 ticket al mese	in Batch
Haiku 5.5	0,000175 $	1,75 $	0,875 $
Sonnet 5.5	0,0035 $	35 $	17,50 $
Opus 5.5	0,007 $	70 $	35 $

- A questo volume la voce che pesa è un’altra: il tempo delle persone che controllano le risposte