

Claude e Claude Code in pratica

Dal prompting agli agenti

Simone Scannapieco

Corso base per Tecnodata Trentina S.r.l., Trento, Italia

Modulo 8 — Costi, piano Pro e ottimizzazione

Ridurre i token

Tre mosse: tagliare, riassumere, recuperare

Quello che non cambia la risposta si può togliere

- Il conto di una richiesta dipende da quanti token porta con sé: il modo più diretto di pagare meno è portarne meno
- A voce: nel prompt che usate più spesso, quale parte non cambierebbe la risposta se la toglieste?
- **Tagliare.** Per Anthropic la maggior parte delle richieste di un agente contiene token che non influenzano mai la risposta, e tagliarli raramente costa in qualità. Nella sua valutazione di un support desk togliere «verify twice» ha ridotto il costo per ticket; e nelle sue misure chiedere risposte più brevi ha tolto circa il 13 % del costo, con il 39 % di token in uscita in meno. Il prompt minimo, però, non è per forza breve: dentro resta ciò che la risposta richiede
- **Riassumere.** `/compact`, seguito da istruzioni, dice a Claude che cosa conservare, ma compattare un contesto grande è di per sé una richiesta grande; `/clear` non costa nulla
- **Recuperare.** Identificatori leggeri al posto dei dati: percorsi, query salvate, link; uno strumento `search_logs` che dà solo le righe utili invece di un `read_logs` che legge tutto; una richiesta specifica invece di una vaga; un percorso invece di `@`, che inietta l'intero file

Si misura prima di tagliare

Il metodo, dalle pagine di Anthropic

- Si parte dai **criteri di successo**, e poi si progettano le valutazioni che li misurano
- Sul proprio carico di lavoro: alcuni task presi dai log di produzione, controlli di esito, il **costo per task** accanto al punteggio
- Su un insieme fisso di task si ottengono baseline e test di regressione su latenza, uso di token, costo per task e tassi di errore
- Lo stesso task due volte, con i due modelli che confrontate: si annotano turni, token in uscita e costo; tre o quattro task, prima di concludere
- I numeri delle pagine riflettono il listino del momento, e cambiano con modelli e prezzi: ogni cifra di questo modulo è datata

Si taglia ciò che non cambia la risposta, e si misura prima e dopo.

Il laboratorio

Due esercizi: la ricevuta, poi il taglio

- **Quanto costa una risposta**, 6 minuti: una chiamata vera, e il conto rifatto da uno script che Claude Code scrive per voi
- **Metà dei token, a parità di qualità**, 22 minuti: il prompt dell'assistenza di CiaspoLink, l'operatore inventato del corso, tre messaggi di clienti, controlli e un giudice; si misura, si taglia con Claude Code, si rimisura
- Da dove si parte: Anthropic dice che tagliare i token che non influenzano la risposta raramente costa in qualità
- L'obiettivo della metà è del laboratorio, un numero da confrontare: conta non perdere qualità